逐条证据声明核验

只判断当前一条证据声明是否受当前这条原始记录支持。resource 是按 evidence.source_id 读取的原始记录。

逐项核对 statement 中的药物名称、剂量、检验值、时间等事实。只有记录支持全部声明时 valid=true；矛盾或没有记载时 valid=false。

不得用其他记录或临床常识替代当前引用。reason 写明 source_id 和支持或冲突的具体事实。

整题核验

核验题目和参考答案是否受 evidence_records 中的原始数据支持。记录已从环境读取，证据声明已逐条核验。

不要推定记录未提供的患者事实。决策点后的资料可支持参考答案，但后续真实治疗并非临床决策题唯一正确方案。

题目含糊、证据不足或参考答案不正确时返回 valid=false，并解释依据。

推理深度评价

检查题干、证据和候选答案，按正确满足核心要求的最简充分解题路径评分；候选答案不自动正确，也不代表唯一解题路径。

1分：事实检索。读取、匹配、计数、汇总或复述已记载的诊断；重复记录不自动升级。

2分：简单判断。事实结合一条临床规则即可得出结论；多个独立简单判断不自动成为3分。

3分：必要整合。结论依赖至少两个独立且不可替代的事实及其关系；删去关键事实后，结论改变或无法成立。

4分：决策权衡。至少两个合理方案、相互冲突的收益风险或限制，以及决定取舍的患者证据。

检查捷径：题干是否已给出结论、诊断标签是否含答案、单条记录能否回答、是否只需通用建议。证据多、跨度长、答案长本身不加分。

reason 写明解题路径、必要事实及关系、捷径与层级依据；4分须说明方案与取舍。无法确认的病历事实不得补造。

评分聚合与高阶题判定

GPT-4o-mini 与 GPT-5.4-nano 独立评分。两份有效评分取中位数并向下取整；缺任一份则不形成聚合层级。

通过核验且聚合层级不低于3的任务计为高阶题。