MedEvolve：数据探索驱动的医疗任务自进化

摘要

纵向医疗记录中的信息分散在不同就诊、时间点和资源类型中。自动构建医疗任务需要发现有意义的临床关系，并使问题、参考答案与可访问证据相互对应。本文提出 MedEvolve，一个数据探索驱动的医疗任务自进化框架。数据探索归纳轨迹中的事件关系与证据约束，环境探索识别工具能力与检索边界，两类知识共同指导任务生成。随后，框架结合证据核验、质量评价、推理深度标注与独立解题反馈，更新生成指导和任务方向的采样配比。实验设计覆盖 PhysicianBench 与 MedAgentBench：实验 1 比较生成任务的可靠性、推理要求、有效产出和成本；实验 2 在模型权重固定的条件下，将合成任务用于 Agent 经验学习，并通过官方任务评测考察其下游价值。

1 引言

1.1 研究背景与动机

基于大语言模型的医疗 Agent 可以通过工具访问电子病历，检索患者信息并完成医疗问答。面向纵向病历的任务要求 Agent 在多次就诊、不同资源类型与分散记录之间组织证据，并理解临床事件的时间关系。因此，这类任务的构建不仅涉及自然语言问题的生成，还需要明确问题所依赖的患者信息、证据范围与答案依据。

人工编写任务能够针对具体场景设计问题，但逐一梳理病历、选择提问内容和核验答案需要投入较多工作。随着数据环境和患者轨迹变化，任务集也需要持续更新。自动任务构建由此提出一个研究问题：如何从已有医疗数据中发现值得提问的临床过程，生成有证据支撑的任务，并使任务分布随解题能力的变化而调整？

1.2 医疗任务构建的挑战

这一问题包含三个相互关联的挑战。首先，任务机会的发现需要理解数据本身。不同医疗环境在资源类型、时间字段、记录密度和临床信息表达方式上存在差异；能够形成有效任务的事件链，需要结合具体患者轨迹识别。例如，围绕用药变化提出问题，需要判断相关记录是否包含足够的时间信息与临床证据。仅确定题型或生成问题文本，尚不足以保证所需证据存在于数据中。

其次，任务需要具有明确的证据依据与可核验的答案。问题文本、可访问记录和参考答案应当相互对应，避免生成缺少支持或含义不明确的问题。对于涉及特定时间视角的任务，还需要明确可用信息的范围，区分作答时能够获取的证据与评估侧用于核验的后续记录。

最后，任务生成策略需要响应解题反馈。通过核验的任务仍可能集中于解题 Agent 已掌握的能力，也可能因证据检索、信息整合或时间推理要求过高而难以完成。解题失败本身不能直接说明任务具有学习价值，还需要区分任务缺陷与解题能力不足。如何利用核验结果和失败归因，调整后续生成指导与任务配比，是持续改进任务生成的关键。

1.3 核心贡献

针对上述挑战，我们提出 MedEvolve，一个数据探索驱动的医疗任务自进化框架。框架将对长程轨迹的理解与对工具环境的验证结合，归纳可跨患者复用的生成指导，并通过任务质量、推理深度与解题反馈迭代调整生成策略。

本文的核心贡献体现在方法创新与学习机制两个层面：

1. **数据-环境双探索机制**。患者轨迹的时间跨度可达数年，记录分散在多次就诊和不同资源类型中，任务所需证据可能跨越多个时间点与资源类型。MedEvolve 将轨迹中的事件关系与工具检索边界共同纳入任务机会的识别。MedEvolve 通过数据探索归纳临床事件关联（如” 用药调整与指标改善” 需要哪些记录、多长时间跨度），通过环境探索验证这些信息的可获取性（工具能否检索、如何组织调用），将两类知识联合建模为任务生成指导。
2. **反馈驱动的策略进化机制**。解题失败本身不能直接说明任务具有学习价值——任务可能因证据不足而无法完成，也可能对解题 Agent 要求过高。MedEvolve 设计独立的质量评价、推理深度标注与完成表现分析，区分任务缺陷与能力不足，并将反馈转化为生成指导的更新与题型难度配比的调整。这使框架能够持续改进任务构建方式，而不是简单积累未通过的题目。

2 相关工作与问题定义

2.1 相关工作

医疗 Agent 与交互式评测。MedAgentBench 将医疗任务置于可交互的电子病历环境中，评估 Agent 通过工具访问患者记录并执行临床相关

操作的能力。PhysicianBench 进一步关注真实病历中的长程复合工作流，通过结构化检查点核验任务执行。这些工作为研究医疗工具使用与纵向信息整合提供了环境和评估基础。MedEvolve 关注如何利用环境中的患者轨迹构建任务，并通过反馈持续改进任务生成策略。MedAgentBench，PhysicianBench。

自动任务构建与环境探索。TaskCraft 从原子任务出发，通过深度扩展和宽度扩展构建具有多步检索与组合要求的 Agent 任务，并结合核验获得任务及执行轨迹。CuES 通过好奇心驱动的环境探索，将交互模式抽象为任务，并结合指导与质量控制生成可执行任务。这些研究说明，任务结构可以从数据关系或环境交互中获得。MedEvolve 在长程医疗轨迹中结合数据探索与环境探索，将对临床记录、事件关联和工具使用方式的理解转化为出题知识，并以任务反馈更新生成策略。TaskCraft，CuES。

反馈驱动的 Agent 改进。Reflexion 将任务反馈转化为语言反思并保存在记忆中，指导后续尝试。AgentEvolver 将自主出题、经验引导和贡献归因结合到 Agent 学习框架中，连接任务生成与能力改进。MedEvolve 将反馈用于医疗任务生成侧：核验与解题结果帮助识别任务缺陷及能力需求，并为后续探索和出题策略更新提供依据。本文通过任务质量、推理深度、完成表现与成本评价这一过程。Reflexion，AgentEvolver。

MedEvolve 的定位。MedEvolve 以纵向医疗记录中的临床关系及其证据要求为任务构建依据，同时用工具交互检查信息获取方式。表 1 比较三类方法的任务构建机制。

本文关注的差异在于生成知识的组织与更新对象：临床模式需要在新患者记录中重新实例化，策略更新则作用于可跨患者复用的出题指导。探索和反馈的独立贡献通过控制组检验，不由方法之间的总体差异直接推断。

2.2 问题定义

给定一个通过工具接口提供长程医疗轨迹数据的可交互环境、固定的解题 Agent 和生成预算，我们研究如何自动构建可核验的医疗任务，并迭代改进任务生成策略。患者轨迹包含随时间积累的就诊、检查、用药及其他临床记录，环境接口提供记录检索与详情读取等操作。任务生成需要同时确定提问内容、允许访问的数据范围以及参考答案依据。

将一个任务记为 $\tau = (p, q, a, E)$，其中 p 为患者，q 为自然语言问题，a 为候选参考答案，E 为支持问题与答案的证据集合。解题 Agent 接收问题与患者上下文，通过环境工具获取作答所需信息；参考答案和证据标注保留在评估侧。

生成策略 $\theta = (g, w)$ 包含生成指导 g 与题型难度配比 w。在固定评估流程与解题配置下，我们研究探索所得知识与任务反馈如何改善生成质量，并改变任务的推理要求和证据结构。任务质量、推理深度与解题完成表现分别评价，避免将解题失败直接视为任务价值。

2.3 任务与评估约束

策略进化与独立评测使用互不重叠的患者集合。同一患者的记录不跨集合，独立评测结果不参与策略更新。各环境的患者规模与抽样规则在实验设置中报告。

任务依据环境中可访问的患者记录构建。涉及临床判断时，参考答案需要区分记录事实与合理推断，并允许证据支持的等价方案。实际发生的后续治疗可以提供背景，但不能直接构成唯一正确的临床方案。任务可附带时间视角属性；是否启用及其访问约束由环境与实验配置确定。本文区分实际启用的访问范围与问题文本中的时间限定。

盲测不向解题 Agent 暴露参考答案或证据标注。不同方法与进化轮次使用一致的核验规则、评分标准和解题配置，环境或模型故障单独记录。

3 方法

3.1 整体思路

长程医疗轨迹中的记录数量与类型并不能直接决定值得提出什么问题。任务生成既需要识别临床事件之间的联系，也需要理解这些信息如何在交互环境中获得。MedEvolve 将这两类理解转化为生成指导，再利用任务反馈调整指导内容与任务分布。

设数据探索与环境探索所得知识分别为 K_D 与 K_E，第 r 轮生成策略为 θ_r。对患者轨迹 X_p，任务生成可表示为

$$\mathcal{T}_{p,r} = G(X_p, K_D, K_E; \theta_r).$$

初始探索提供跨患者的知识基础，具体任务仍由当前患者的真实记录支持。每轮任务经过核验、质量与难度评价以及独立解题，形成反馈 F_r，随后更新策略

$$\theta_{r+1} = U(\theta_r, F_r).$$

这一过程将对数据与环境的初始理解同持续的策略调整联系起来。探索指导在后续轮次中复用，反馈更新生成指导与题型难度配比。

表 1. 自动任务构建方法的机制比较。

维度	TaskCraft	CuES	MedEvolve
构建依据	原子任务及其深度、宽度扩展	环境交互轨迹与任务抽象	医疗轨迹模式与环境指导
知识组织	任务依赖与组合结构	环境记忆、概念与可执行模式	临床事件关系、证据约束与工具边界
反馈作用	内部核验与生成流程优化	质量控制与任务改写	跨患者生成指导与方向配比更新
研究侧重	可扩展的多步 Agent 任务	环境驱动的 Agent 训练任务	纵向医疗任务的证据组织与策略进化

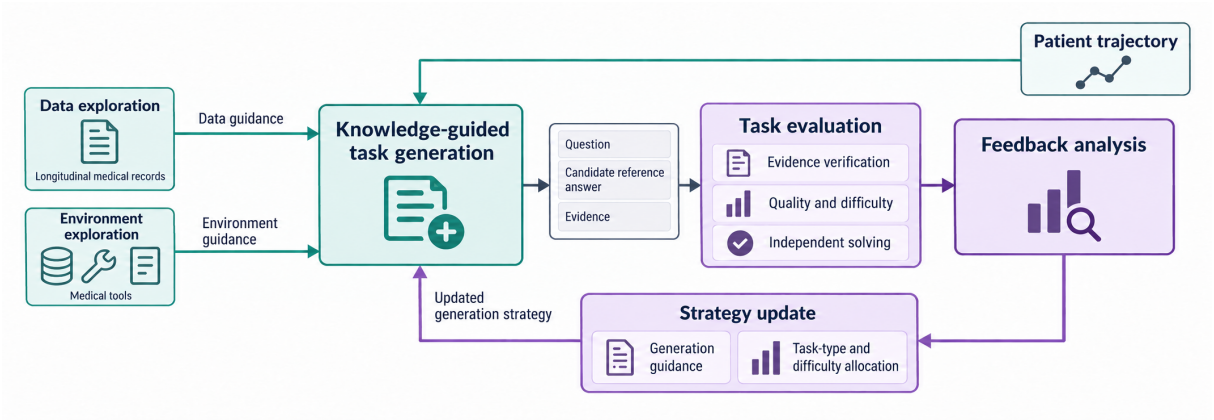


图 1. MedEvolve 方法概览。数据探索与环境探索分别形成生成指导，任务评价反馈用于更新生成指导和题型难度配比。

3.2 数据与环境探索

任务机会取决于记录之间的关系及其可获取性。例如，比较用药调整前后的检查结果，需要定位调整事件、相关指标和时间窗口；检查次数较多并不意味着这些条件同时成立。MedEvolve 在初始阶段分别探索患者数据和工具环境，得到数据指导 K_D 与环境指导 K_E。

数据探索。探索 Agent 从进化患者集合中读取缓存轨迹，归纳记录的组织方式、时间变化、事件关联及可支持的提问模式。轨迹读取受模型上下文预算约束，裁剪或压缩材料保留覆盖标记。模型不能依据摘要或裁剪材料中缺少某条记录，断言原始病历中不存在相应事实。原始来源保留供后续证据核验。

数据指导以可复用的自然语言规则表达临床模式及其证据要求。例如，比较治疗前后的指标变化，需要对应的治疗记录、时间可定位的检查及可比的数值或描述。观察到的时间先后支持变化分析，但不能单独证明治疗与结局的因果关系。指导不保存患者标识、个体检查值或具体来源编号，具体问题仍由目标患者的记录支持。

环境探索。探索 Agent 在独立实例中实际调用开放患者范围内的只读工具，识别参数、返回结构、分页及结果裁剪等约束。环境指导明确区分已验证能力、调用失败与未验证能力，并记录定位证据和读取详情的可行方式。工具声明本身不构成能力已经验证的证据。

两类指导在初始阶段形成，随后固定复用。数据指导提供提问模式，环境指导约束证据获取方式；二者的固定部分与后续更新的生成策略分别保存。探索成本按实际调用记录，在整个任务构建流程中摊销。

3.3 知识引导的任务生成

对患者 p，生成器接收预算内轨迹 X_p、探索指导 (K_D, K_E)、生成指导 g_r 和两个采样方向。每个方向包含临床题型、自然语言难度要求及其采样权重。题型限定为诊断与解释、检查与风险分层、治疗规划、药物处方和治疗重规划。

生成器通过一次模型调用完成模式选择与任务构建。它先判断当前记录能支持哪些提问，再围绕相应证据形成问题、候选参考答案和来源声明。跨记录结论分别引用相关依据，答案区分记录事实与临床推断，并允许有证据支持的等价方案。生成指导和方向配比共同约束候选选择，不强制模型将每个患者实例化为相同临床模式。

候选批次经过结构、数量、题型与来源检查。每位患者最多输出两道任务，生成不足和批次拒绝均保留在产量与成本记录中，不通过

补造事实填满数量。对时间字段缺失或必要记录不足的情境，问题和答案必须明确证据边界。

证据核验。公共核验从环境重新读取每条引用的原始记录，检查该记录是否支持对应声明，再判断整道任务的证据支持性与清晰度。通过核验的任务进入质量、难度与独立解题评价。核验未通过的任务保留原因，仍可用于生成缺陷的反馈分析；缺少可靠解题评价时，不据此推断解题能力不足。

核验与质量评价分别承担来源一致性检查和任务构建评价。两者均可能受模型判断偏差影响，实验分别报告核验通过率、评价覆盖和质量分布，并通过人工审查分析其一致性。

3.4 反馈驱动的策略进化

生成侧的进化对象是策略 $\theta_r = (g_r, w_r)$，解题 Agent 的模型与执行设置在对应实验条件下保持固定。通过核验的任务分别获得四维质量评分、四级推理深度和完成评价；执行轨迹保留工具使用、预算与故障信息。质量、推理要求和解题表现共同进入反馈，低完成率本身不作为任务价值的依据。

反馈归因。反馈分析按患者组织当前任务、轨迹和评价，归纳事实错误、证据不足、题意歧义及可能的检索或推理困难，再汇总为跨患者发现。工具、环境、模型故障和预算耗尽与临床失败分开记录。高质量任务上的解题失败可提供能力需求的线索，但这一判断仍需结合执行轨迹与评分可靠性。

策略更新。更新函数 U 依据当前策略和反馈修订生成指导，以及带题型和难度描述的方向权重。例如，证据不足的反馈可转化为选择时间窗口或组织引用的约束；不同方向上的质量与完成表现可影响后续采样配比。权重非负且至少一项为正，策略不保存患者特定答案。

进化患者按轮次划分，每轮生成和评价后执行反馈分析与策略更新。初始探索指导保持固定，轮次结束后冻结生成策略，并在患者独立的评测集合上生成任务。初始与最终策略的控制比较使用同一评测患者集；进化轮次之间患者组成不同，其逐轮指标同时反映策略与样本变化。

4 实验

4.1 研究问题

实验分别评价生成任务的构建水平与下游学习价值，并通过组件分析解释其来源。

1. **质量与推理要求**。不同方法能稳定产出多少可核验任务？其质量、推理层级和纵向证据结构如何分布？
2. **下游价值**。在模型权重固定时，不同任务来源积累的经验能否改善官方医疗任务上的完成表现？
3. **机制贡献**。数据探索、环境探索和反馈更新分别如何影响生成结果？
4. **收益与投入**。生成策略和解题经验的收益需要多少探索、生成、评价与学习成本？

4.2 实验设置

环境与患者。实验设计覆盖 PhysicianBench 与 MedAgentBench，复用其患者记录和原生工具接口。两个环境分别建立患者名单与独立实例，跨环境成绩分别报告，不按统一分数合并。患者数量和生成侧划分见表 2；记录密度、时间跨度和资源类型覆盖按实际轨迹统计。

划分以种子 42 为基础，进化集占约四分之一。最终名单在兼容既有探索暴露范围的约束下冻结，以保证已用于探索的患者不进入独立评测集。MedAgentBench 使用官方病历患者范围，不纳入仅有 Patient 资源的额外记录。名单与抽样约束见附录 B。

模型与公共协议。生成比较分别使用 GPT-5.4-nano 和 GPT-4o-mini。同一生成模型条件下，各方法共享患者集合、最大出题数量、公共核验、评分标准和解题模型。独立解题使用对应生成模型，跨模型结果分别解释。正式汇总采用 GPT-5.4-nano 与 GPT-4o-mini 两模型的质量和难度评分；核验与完成裁判使用 GPT-5.4-nano。不同裁判协议的结果分别标识，仅统一协议的结果进入同一主比较。

模型输入按上下文预算选取轨迹材料，原始来源保留用于核验。各方法每位患者最多生成两题；相同出题上限不意味着相同调用成本。探索、内部生成与检查、策略更新和公共评价的实际用量分别记录，内部预算与运行限制见附录 C。

对比方法。 MedEvolve 与五种方法在同一公共接口下比较。

方法	任务构建机制	跨患者更新
MedEvolve	数据与环境双探索引导单次生成	更新生成指导与方向配比
TaskCraft	原子任务构建、内置核验、深度与宽度扩展	固定生成流程
Workflow	定位、生成与内部检查	固定生成流程
SingleShot	根据患者轨迹单次生成	固定生成流程
SelfRefine	初稿、自反馈与当前批次修订	反馈只作用于当前患者
EnvExplore	环境探索指导生成	固定初始策略

TaskCraft 和 SelfRefine 为原方法的医疗任务生

表 2. 生成侧患者划分。进化集与评测集患者不重叠，两个生成模型与六种方法共享评测名单。

环境	患者总数	进化集	独立评测集	两轮进化患者数
PhysicianBench	108	27	81	13 / 14
MedAgentBench	100	25	75	12 / 13

成适配，适配边界见附录 C。CuES 在相关工作中讨论。EnvExplore 同时缺少数据探索与跨轮更新，其与完整方法的差异不能单独归因于某一组件。

4.3 评价指标与统计口径

有效性与质量。实际生成量、核验覆盖与核验通过率共同描述有效产出。通过率以具有核验结果的任务为分母；核验缺失、运行故障及生成不足分别报告。质量从事实准确性、临床合理性、证据充分性与题目清晰度四个维度按 1–5 分评分，各维度分别报告均值、分布及不低于 4 分的比例。评分只覆盖核验通过且该评价阶段成功的任务，不解释为全部请求任务的平均质量。

推理与证据结构。推理深度包含事实查询、单步推理、整合推理和临床决策四级，报告层级分布，高阶推理定义为第 3–4 级。去重来源数、资源类型数与引用记录时间跨度描述证据结构，不直接视为推理难度。时间信息缺失时保留缺失标记。

质量与难度分别由两个模型独立给出整数评分。聚合采用整数中位数，两分数中位数为小数时向下取整；原始评分和理由同时保留。人工一致性与裁判分歧作为补充分析，聚合规则见附录 D。

完成表现与成本。生成任务的完成率分别以全部生成任务、具有完成评价的任务为分母。运行结束状态与是否完成任务分开解释：评价流程结束不等于解题成功。生成侧成本按模型调用、输入和输出 token 汇总，核验与解题等公共评测成本单列；缺失用量不以零替代。

不确定性。方法级结果按环境和模型分别汇总，并同时报告患者数和任务数。置信区间以患者为单位重采样，在相同患者集合上比较的方法保留患者配对。实验 2 的初始与最终状态在同一测试题上配对；患者级区间只表示测试样本不确定性，单次训练的区间不代表跨训练运行稳定性。具体规则见附录 D。

4.4 实验 1：生成任务的质量与推理要求

实验 1 在独立评测患者集上比较六种生成方法，围绕可靠性、推理要求与实际产出解释结果。表 3 报告产量和核验，表 4 展开质量维度，表 5 展开推理和证据结构。每张表按环境及生成模型分别呈现；空值表示正式结果尚未填入，不代表零产出或零分。

图 2. 任务有效性与推理层级分布。按全部生成任务归一化的堆叠条形图分别呈现核验未通过、评价缺失及有效任务的四个推理层级；运行故障单列。环境与生成模型分面展示，分母和任务数量标于图中。

图 3. 四维任务质量。四个面板分别展示核验通过任务的质量均值与患者级 95% 置信区间，所有面板使用相同方法顺序和 1–5 分坐标范围。

结果分析同时考察核验通过率、高阶题数量和质量分布。更高的推理层级只有在证据支持与任务清晰度成立时才构成有效挑战；较高的质量均分也需要结合产量和推理分布解释。对证据数量、推理层级和临床题型分层报告核验情况，以识别复杂任务与生成缺陷之间的关系。

4.5 实验 2：合成任务驱动的 Agent 经验学习

实验 2 固定模型权重，将不同方法生成的任务用于 Agent 的技能、记忆或策略手册更新。实验条件为任务来源与 Harness 的组合：六种来源分别接入 OpenClaw、Hermes Agent、ACE 和 Reflexion，同一环境共有 24 个学习组。来源比较在同一 Harness 内进行，Harness 比较报告相对其自身初始状态的变化。

任务冻结与训练。每个来源只纳入核验通过且完成条件为只读的任务，固定数量不超过各来源的最小有效产量。以种子 42 抽样，按任务划分为 70% 训练集和 30% 合成测试集，训练数向下取整。PhysicianBench 当前运行配置每来源选取 25 题，训练 17 题、辅助测试 8 题；其他环境的实际数量以冻结清单为准。同一来源在四种 Harness 中共享任务、划分和顺序。

训练期间每题新建解题会话与医疗实例，跨题只保存经验，不继承完整对话。参考答案和证据不进入本题初始解题输入，执行后供评审和经验更新使用。学习组从各 Harness 的统一初始状态出发，完成固定训练轮次后冻结最终经验；选择最终状态，不依据测试成绩选择经验版本。故障与学习未触发单独记录。

当前 PhysicianBench 配置使用 GPT-4o-mini 执行、辅助分析和经验更新，训练一轮、种子 42、一次运行。同一 Harness 内各来源保

表 3. 生成任务的产量与核验。每个环境与生成模型分别报告患者覆盖、实际产量、核验覆盖和通过情况。

方法	生成患者数	生成题数	核验题数	通过题数	核验通过率
MedEvolve	—	—	—	—	—
TaskCraft	—	—	—	—	—
Workflow	—	—	—	—	—
SingleShot	—	—	—	—	—
SelfRefine	—	—	—	—	—
EnvExplore	—	—	—	—	—

表 4. 核验通过任务的四维质量。均值附患者级 95% 置信区间；评分题数明确评价覆盖。

方法	评分题数	事实准确性	临床合理性	证据充分性	题目清晰度
MedEvolve	—	—	—	—	—
TaskCraft	—	—	—	—	—
Workflow	—	—	—	—	—
SingleShot	—	—	—	—	—
SelfRefine	—	—	—	—	—
EnvExplore	—	—	—	—	—

持模型、训练数量、轮次及原生限制一致。Harness 的实际学习机制、执行限制和经验隔离见附录 E。

官方任务上的共同评测。 PhysicianBench 与 MedAgentBench 的官方任务承担主要外部评价。同一环境和 Harness 下，各来源最终经验与统一初始经验在相同官方任务、模型、工具和执行限制下评测。官方题目、参考答案及评分反馈不参与合成任务生成或经验训练。测试关闭经验写入和后台学习，每题使用冻结快照的临时副本、新会话与独立医疗实例。

评分采用各环境的官方原生规则：PhysicianBench 记录任务成功与检查点成绩；MedAgentBench 按锁定任务版本和官方评分逻辑判定完成。官方任务按其原生要求开放工具和文件交付，不沿用合成训练任务的只读限制。两个环境的分数分别报告，实际数据版本、评分资产和任务覆盖见附录 E。

设官方任务集为 B，初始与最终经验状态分别为 h_0 与 h_m。任务成功率及百分点提升定义为

$$A(h) = \frac{1}{|B|} \sum_{i \in B} \mathbf{1}[\text{success}(i, h)],$$
$$\Delta_m = 100\big(A(h_m) - A(h_0)\big).$$

主成绩使用计划任务总数为分母，并单列运行与评分故障、有效评分数及覆盖率。初始与最终均获得有效评分的同题配对集合另报提升及区间，不能用配对子集掩盖完整测试覆盖。

图 4. 官方任务成功率的配对提升。以零为中心的点图展示各来源相对初始经验的百分点变化与患者级 95% 置信区间；按环境和 Harness 分面，统一来源顺序。完整计划任务覆盖与配对样本数随图报告。

合成任务上的辅助验证。各来源的 30% 合成测试集分别比较初始与最终经验，只解释为该来源任务分布上的迁移。不同来源的测试题不同，其绝对成功率或提升不用于跨来源排名。任务级划分可能共享患者，患者重叠与题目近重复分别审查，不将这种结果描述为未见患者泛化。

生成侧评测患者独立于生成策略进化患者，但这些患者的合成题可以进入经验训练；因此，生成侧的患者独立性不自动保证官方任务评测的患者独立性。经验训练与官方测试的患者重叠单独报告。实验 2 的主要问题是任务来源能否改善共同官方任务的表现，推理深度或经验条目数量本身不作为学习收益。

4.6 探索、策略进化与成本分析

组件消融。组件效应采用配套控制组分析。固定策略组保留双探索，仅使用初始生成策略；去数据探索组保留环境指导，并采用与完整方法一致的反馈更新；去环境探索组保留数据指导，并采用同样更新。各组共享进化与评测患者、模型、出题上限和公共评价。既有 EnvExplore 作为只保留环境探索与固定策略的组合对照。

策略进化。初始与最终策略在同一未见患者集合上比较，保留相同探索指导、生成模型、出题上限和评价协议。报告有效产出、质量和推理分布的变化，并结合指导文本与方向权重分析变化来源。两轮进化采用不同患者，训练侧逐轮数据作为过程描述，不直接作为策略收

表 5. 推理要求与证据结构。高阶题占比以有难度评分的任务为分母，同时报告高阶题数量；证据跨度采用中位数，并附时间可解析覆盖。

方法	高阶题数 / 评分题数	高阶占比	平均证据数	平均资源类型数	跨度中位数（天）
MedEvolve	—	—	—	—	—
TaskCraft	—	—	—	—	—
Workflow	—	—	—	—	—
SingleShot	—	—	—	—	—
SelfRefine	—	—	—	—	—
EnvExplore	—	—	—	—	—

表 6. 官方任务上的经验学习效果。每个环境单独成表，四个 Harness 分别比较六种任务来源；单元格为最终成功率及相对该 Harness 初始状态的百分点变化，95% 置信区间另附。初始状态行只报告成功率。

任务来源 / 状态	OpenClaw	Hermes Agent	ACE	Reflexion
初始状态	—	—	—	—
MedEvolve	—	—	—	—
TaskCraft	—	—	—	—
Workflow	—	—	—	—
SingleShot	—	—	—	—
SelfRefine	—	—	—	—
EnvExplore	—	—	—	—

益的控制比较。

图 5. 策略更新与生成投入。面板 A 在固定评测患者上对比初始与最终策略的有效任务和推理分布；面板 B 报告探索、生成、反馈及策略更新的累计 token。没有固定评测结果的中间轮次不连成收益曲线。

人工审查。人工审查按方法、推理层级与核验状态分层抽取任务，覆盖核验通过和未通过样本。两名具有医学背景的评审在不知方法来源和模型评分的条件下检查问题、参考答案及原始证据，分别记录质量、推理层级和证据错误；分歧经复核记录。报告抽样构成、评审一致性和模型核验的误判情况，不由核验通过样本外推全部任务的质量。

成本。生成成本包含探索、方法内部生成与检查、反馈和更新；公共核验、质量评价、解题与完成评审单列。经验学习分别统计训练执行、经验更新与测试成本，任务集被多个 Harness 复用时生成成本只计一次。报告总调用和 token，并以核验通过任务数归一化生成成本；无有效任务时单位成本记缺失。价格或用量缺失时不估算金额。相同题数实验检验固定样本预算下的效果，不等同于相同计算预算。

4.7 案例分析

纵向案例从实际生成任务中选取，串联抽象指导、患者记录、问题、答案与引用证据。展示记录之间的时间关系、哪些结论由多个来源支持，以及哪些事实不足以支持进一步推断。生成侧策略变化案例采用同一患者上的初始与最终策略任务，并保留两者的核验与质量结果。

失败案例按生成缺陷和解题困难分别呈现。证据未支持的声明明确定位到原始记录；核验通过但未完成的任务结合检索轨迹解释困难，不将故障作为临床失败。经验学习案例展示可迁移规则及其在另一测试题上的使用，不以单个成功案例替代总体评测。

图 6. 纵向医疗任务的证据链。时间轴标注治疗与检查事件，问题和参考答案分别连到支持来源，模型推断与病历直接事实分开标识。例题、日期和数值均来自审查后的实际任务。

5 讨论与结论

5.1 局限性

数据与证据边界。自动构建任务受患者记录、时间信息和工具接口限制。轨迹裁剪、缺失记录及不同机构的表达差异影响模式识别；可解析的时间跨度与来源类型也不能完整描述临床信息量。同一数据环境中的患者划分与跨机构、跨数据来源泛化分别解释。

模型评价。两模型聚合不能消除共同偏差，临床合理性也未必由结构化记录充分判定。质量评分覆盖核验通过任务，复杂任务的证据声明较多，整题核验更容易因其中一条不成立而失败。评价需要同时呈现产量、覆盖、分布和人工审查，不以筛选后的均分代表整个任务生成过程。

表 7. 探索与反馈更新的控制配置。结果按环境与生成模型报告核验通过率、四维质量、高阶有效题数量和成本。

配置	数据探索	环境探索	反馈更新	正式结果
完整 MedEvolve	是	是	是	—
固定初始策略	是	是	否	—
去数据探索	否	是	是	—
去环境探索	是	否	是	—
EnvExplore	否	是	否	—

难度与学习价值。高推理层级、较多引用或较长时间跨度描述不同方面的任务要求，不保证任务适合学习。解题成绩受模型、工具与预算共同影响。生成侧的策略更新和解题侧的经验学习是两个不同过程，其效果分别由生成控制比较和共同官方任务评价支持。

经验迁移与稳定性。合成训练与辅助测试按任务划分，可能共享患者；官方任务也可能与经验训练共享底层记录。患者重叠和答案近重复需要单独报告。当前单种子训练不能说明跨运行稳定性，患者重采样区间只衡量测试样本的不确定性。原生 Harness 的学习触发与调用限制存在差异，跨来源比较优先在同一 Harness 内进行。

5.2 结论

MedEvolve 将纵向医疗记录的数据探索、工具环境探索和任务反馈连接到生成策略更新。框架以可复用的临床模式与证据约束指导出题，并分别评价任务可靠性、推理要求、有效产出和成本。实验 1 检验生成结果，实验 2 在固定模型权重下通过共同官方任务评价合成任务的经验学习价值；组件控制、人工审查及成本分析限定这些结论的解释范围。

参考文献

Jiang, Yixing, et al. 2025. MedAgentBench: A Realistic Virtual EHR Environment to Benchmark Medical LLM Agents. arXiv:2501.14654.

Liu, Ruoqi, et al. 2026. PhysicianBench: Evaluating LLM Agents in Real-World EHR Environments. arXiv:2605.02240.

Shi, Dingfeng, et al. 2025. TaskCraft: Automated Generation of Agentic Tasks. arXiv:2506.10055.

Mai, Shinji, et al. 2025. CuES: A Curiosity-driven and Environment-grounded Synthesis Framework for Agentic RL. arXiv:2512.01311.

Shinn, Noah, et al. 2023. Reflexion: Language Agents with Verbal Reinforcement Learning. arXiv:2303.11366.

Zhai, Yunpeng, et al. 2025. AgentEvolver: Towards Efficient Self-Evolving Agent System. arXiv:2511.10395.

Madaan, Aman, et al. 2023. Self-Refine: Iterative Refinement with Self-Feedback. arXiv:2303.17651.

A 探索与生成接口

A.1 数据探索

探索工具提供开放患者名单、预算内轨迹及可选压缩摘要。输入材料保留患者标识、原始来源和覆盖标记，输出为不绑定患者的自然语言指导。指导归纳数据组织、时间变化、事件关系、证据引用与可支持的问题，不保留个体临床值或来源编号。

压缩摘要用于定位模式，原始记录用于支持具体事实。记录缺失与材料裁剪分别解释。指导中的时间窗口、记录数量或临床关系属于模型归纳的提问约束，不构成对所有患者统一适用的硬编码医学规则。

A.2 环境探索

环境探索在独立实例中访问开放患者的原生只读工具。指导记录已验证参数、返回结构、分页与裁剪行为、典型检索方式，并区分调用失败和未验证能力。环境内的具体患者观察不进入通用指导。

A.3 任务生成与策略

任务包含患者标识、临床题型、问题、候选参考答案、来源标识与逐来源事实声明，以及可选时间视角和执行要求。生成调用输入预算内轨迹、两类探索指导、当前生成指导和两个采样方向，输出最多两题。

生成策略由自然语言指导和方向列表组成；方向包含五类临床题型之一、难度描述与非负权重。方向按权重采样，允许同一题型对应不同临床模式；至少一个权重为正。数据与环境指导在策略更新期间固定，更新只修订生成指导和方向列表。

B 环境、患者与信息访问

PhysicianBench 的生成患者池为 108 人，MedAgentBench 为官方范围内的 100 人。按种子 42 和既有探索暴露约束冻结进化与评测名单。进化患者分为互不重叠的两轮：PhysicianBench 为 13 与 14 人，MedAgentBench 为 12 与 13 人；评测患者分别为 81 与 75 人。

原始轨迹按记录时间组织，模型输入按预算选取；证据核验读取原始来源，不以输入摘要替代来源。初始探索和任务生成只开放查询工具。解题工具依环境与任务执行要求提供，经验训练的合成任务进一步限定为只读。当前 PhysicianBench 生成配置未启用时间视角属性，问题中的时间限定不等同于服务端隐藏后续记录。

经验学习另按合成任务划分训练与辅助测试，不能与生成侧患者划分混用。冻结清单记录选中题目、患者、训练与测试划分、文件摘要及生成来源。官方任务评测另记录任务版本、患者范围及与经验训练的重叠。

C 生成方法与预算

TaskCraft 将患者记录与只读 FHIR 工具映射到原方法的结论抽取、原子任务生成、核验与扩展流程。深度和宽度分支均从原子任务出发，彼此没有先后依赖；两条分支共享生成总预算。原子、深度和宽度候选的实际产量及接纳情况分别记录，以区分扩展机制和最终筛选的影响。医疗适配与原论文完整实验复现分别解释。

Workflow 固定执行定位、生成和内部检查，检查只筛选候选。SingleShot 根据轨迹单次生成最多两题。SelfRefine 在同一患者批次内执行初稿、自反馈和修订，最多三次自评、两次修订，全部通过时提前结束。EnvExplore 先获取环境指导，再用固定初始策略生成任务。各方法共享输出结构和公共评价，内部调用与筛选记录分别保存。

主方法初始探索完成后执行两轮生成侧策略进化，每轮按患者归纳反馈并汇总更新。批次输出的结构或配额校验失败保留为生成失败。反馈和更新调用失败不视为进化成功。输入裁剪、实际调用与预算耗尽分别记录。

模型路由、上下文上限、输出限制和工具预算以冻结运行配置为准。同一比较中报告各方法预算与实际用量；相同出题数量不表述为严格相同 token 预算。探索和更新计入主方法总成本，公共评价成本单列，历史复用调用按原始记录去重计数。

D 评分、汇总与统计

D.1 质量与推理深度

推理深度依据问题要求及证据结构标注：第 1 级直接读取事实，第 2 级结合记录与临床知识完成单步判断，第 3 级跨记录比较或整合信息，第 4 级综合证据权衡风险收益并提出方案。临床题型与推理层级分别记录，不把治疗规划题自动判为最高层级。

对任务 i、质量维度 d，两个模型的原始评分为 $s_{i,d}^{(1)}$ 与 $s_{i,d}^{(2)}$，最终评分为

$$s_{i,d} = \left\lfloor \text{median}\left(s_{i,d}^{(1)}, s_{i,d}^{(2)}\right) \right\rfloor .$$

难度采用同样聚合规则，保留两个原始层级与理由。正式协议要求两份有效输出，不以单个成功裁判替代缺失评价。质量评分材料包含题目、参考答案、证据、轨迹与核验结果；难度评分依据任务要求和自动复杂度。原始评分用于分歧分析。

表 8. 四维质量评分标准。各维度独立评分。

分数	事实准确性	临床合理性	证据充分性	题目清晰度
5	数值、单位、药物、剂量与时间准确	推理严密，方案与风险考虑充分	关键事实和结论均有明确支持	目标、背景与操作要求明确
4	核心准确，存在次要细节瑕疵	基本合理，个别步骤有不足	主要结论有支持，细节引用不完整	基本清晰，个别细节需推断
3	多数准确，少量非关键错误	方向正确，但遗漏重要考虑	核心结论有支持，部分推理缺引用	方向明确，但缺关键背景
2	关键事实错误	有明显漏洞或违背常规实践	关键结论缺支持	目标模糊、矛盾或缺必要限定
1	多处严重错误或编造数据	推理错误或方案有明显风险	主要依赖未支持的推断或编造	无法理解或执行

D.2 证据结构与比率

对引用来源去重得到 S_i，证据数量为 $|S_i|$，资源类型数由可识别类型前缀去重得到。引用记录中可解析的时间集合为 T_i，其跨度为

$$\Delta_i = \frac{\max T_i - \min T_i}{1\ \text{天}}.$$

无可解析时间时记缺失，只有一个可解析时间时为零。报告时间可解析任务数，跨度分布和中位数仅使用非缺失值。

分母为零时记缺失。质量均值、层级分布和证据结构分别报告覆盖数。临床失败、证据不足、题意歧义、工具故障、环境故障与模型故障分别汇总，不由运行状态推断任务完成。

D.3 不确定性与人工审查

统计方案以患者为簇，进行 1,000 次有放回重采样，种子为 42，取分布的 2.5% 与 97.5% 分位数作为 95% 区间。患者的全部题目共同进入样本，相同患者上的方法差异保留配对。重采样分母为零的指标记缺失，不转换为零；区间随指标有效重采样次数报告。

官方任务的初始与最终状态先按任务标识配对，再按患者簇重采样；共同任务和共同有效评分分别报告。单次训练结果不附跨训练标准差。人工审查保留方法、推理层级与核验状态的抽样构成，独立评分后复核分歧，报告各维度一致性及核验误判类型。

E 经验学习与官方评测

各组独立保存配置和经验，从统一初始状态开始。Reflexion 的跨任务经验提炼为医疗适配：保存适用条件、操作步骤和错误教训，不保存患者标识、个体临床值或逐题答案；新题按冻结规则读取最多三条相关经验。测试不根据评分进行反思或重试。

PhysicianBench 当前配置每来源 25 题，训练 17 题、辅助测试 8 题，训练一轮、种子 42。执行与经验更新使用 GPT-4o-mini，单题执行轮次上限 30、工具调用上限 200、执行超时 900 秒，学习轮次上限 10、超时 300 秒。各 Harness 采用原生可用限制，后台调用或原生组件内部用量无法完整计数时标为未知，不表述为统一硬预算拦截。

官方评测锁定任务与评分资产版本。PhysicianBench 使用官方任务和检查点评分，提供实际文件交付、执行轨迹和本题 FHIR 实例；任务成功率与平均检查点得分分别报告。MedAgentBench 按冻结配置选择任务版本并使用官方完成评判，版本间结果分别报告。官方资产缺失或评分故障保留为不可用结果，不以公共模型裁判替代原生分数。

测试评分与解题隔离，评分完成前保留实际使用的医疗实例。每题使用冻结经验副本，不将参考答案、评分结果或完整会话回写到最终经验。测试前后核对冻结经验摘要，报告计划任务数、评分覆盖、初始与最终成绩以及完整与配对口径的提升。

F 补充结果与案例

补充结果按环境、生成模型和方法报告质量分布、临床题型、推理层级、证据跨度及故障构成。TaskCraft 另报告原子与扩展候选的产量和最终接纳比例。合成辅助测试按来源报告初始与最终成绩、患者重叠和配对样本量。

案例保留问题、候选参考答案、原始证据、核验与质量结果，以及相关解题轨迹。临床事实、模型推断与可迁移经验分别展示，时间轴仅使用实际记录。正式表格中的空值表示结果未填入，缺失评价与不适用指标在正式结果中分别标识。

表 9. 生成任务的比率分母。

指标	分子	分母
生成覆盖率	实际生成题数	请求题数
核验覆盖率	具有核验结果的题数	实际生成题数
核验通过率	核验通过题数	具有核验结果的题数
高阶题占比	深度为 3–4 的题数	具有难度评分的题数
维度高质量占比	该维度评分不低于 4 的题数	具有该维度评分的题数
全部生成任务完成率	判定完成题数	实际生成题数
已评价任务完成率	判定完成题数	具有完成评价的题数

表 10. 四种 Harness 的经验载体与更新机制。

Harness	持久化经验	训练更新	测试状态
OpenClaw	技能与独立状态目录	原生 Skill Workshop，记录是否触发	读取冻结技能，关闭学习与后台维护
Hermes Agent	技能与记忆	原生技能和记忆机制	保留读取，关闭写入与整理
ACE	策略手册	Reflector 和 Curator 更新	只运行 Generator
Reflexion	反思与可迁移经验	失败反思及限定次数重试	只运行 Actor，读取经验