面向纵向电子健康记录的 Agent 任务生成：证据锚定与策略进化

摘要

从纵向电子健康记录（EHR）中为医疗 Agent 生成高质量任务面临挑战：不同患者记录能够支持的临床关系各不相同，而可用工具又限制了证据的检索方式。本文提出 MedEvolve，从任务证据锚定与策略进化两个互补层面改进医疗任务生成。在任务构建层面，双探索将反复出现的临床时序模式与工具访问约束提炼为可复用的指导。在策略层面，反馈驱动的进化进一步将核验与独立解题结果转化为跨患者的任务构建规则和任务方向偏好，而非仅修复单个问题。在两个基准上，MedEvolve 的核验通过高阶任务产出率均高于基线方法。加入其合成任务后，ACE 与 Reflexion 在官方测试任务上的成功率分别提高 6 和 2 个百分点。

1 引言

纵向电子病历记录患者多次就诊中的诊断、检查与治疗，是构建医疗 Agent 任务的主要数据来源。MedAgentBench 与 PhysicianBench 在此类环境中评测 LLM Agent（Jiang et al., 2025; Liu et al., 2026），但任务通常依赖临床专家设计与审核，难以大规模扩展。自动生成方法中，TaskCraft 从网页、PDF 和图像生成任务，并通过深度与宽度扩展提高复杂度（Shi et al., 2025）；CuES 通过环境交互探索并合成任务（Mai et al., 2025）。两者均未针对纵向病历结构及只读工具下的证据获取约束设计。

纵向病历任务生成面临两个困难。首先，任务是否成立同时取决于病例内容与工具能力：当前患者轨迹无法揭示跨患者反复出现的临床关系及其证据分布，完整轨迹也可能超出输入预算；所需证据能否通过工具检索，还需实际交互核查。其次，固定生成指导难以在不同病例上维持稳定的质量与难度，问题往往在证据核验或独立解题后才暴露。

本文提出 MedEvolve，通过数据与环境双探索提炼可复用指导，再利用核验与独立解题反馈，跨患者更新生成策略，整个过程不更新模型参数。主要贡献包括：（1）结合临床事件模式与工具访问约束，支持有证据依据的任务生成；（2）利用评价反馈修订自然语言生成指导和任务方向权重；（3）在两个 EHR 环境中评价有效高阶任务产出，并检验合成任务的下游经验学习价值。

2 方法

2.1 问题设置

给定医疗环境 $\mathcal{E}$ 和纵向患者轨迹集合 $\mathcal{D} = \{X_p\}$，目标是为每条轨迹 X_p 构造医疗 Agent 任务。每个任务由指令 q、候选参考答案 a 和来源证据 e 组成。生成过程由策略 $\theta_r = (g_r, w_r)$ 控制：g_r 是自然语言生成指导，w_r 是任务类型和难度方向的采样权重，r 为进化轮次。MedEvolve 先通过探索得到数据指导 K_D 与环境指导 K_E，再利用评价反馈更新 θ_r。整体流程见图 1。

2.2 数据探索与环境探索

单个患者的轨迹只说明该病例包含哪些记录，难以判断这些记录在整个数据源中属于何种模式，也无法在每次生成时重复读取大量患者。因此，我们在生成之前先进行数据探索，把跨患者的观察整理为可复用的指导。

数据探索针对纵向患者轨迹。探索 Agent 读取多位患者的记录，分析数据的组织方式、时间变化、临床事件之间的关联和证据分布，归纳出不同类型任务所需的信息模式，形成数据指导 K_D。K_D 只描述可复用的模式，不包含特定患者的临床事实。

环境探索针对环境接口。探索 Agent 实际调用只读查询工具，记录访问方式、返回结构和交互约束，形成环境指导 K_E，用于判断一个问题所需的证据能否通过工具获取。

两类探索在初始化阶段完成，之后的所有轮次中保持不变。

2.3 任务生成与评价

对于患者 X_p，生成器以 K_D、K_E 和当前策略 θ_r 为条件，按指定的任务类型和难度方向生成 (q, a, e)，其中关键事实附带对原始记录的引用。

候选任务随后依次经过核验、评分和独立解题。核验重新读取原始记录，检查证据声明对参考答案的支持；通过核验的任务再接受任务质量和推理深度的评价，并由固定的 Agent 在环境中独立作答。解题 Agent 无法获得参考答案和证据声明。

2.4 反馈驱动的策略更新

每轮结束后，系统汇总该轮任务的核验缺陷、质量与推理评分以及解题轨迹，归因得到反馈 F_r。归因需要区分任务本身的缺陷（如事实错误、证据不足、题意歧义）、任务带来的真实推

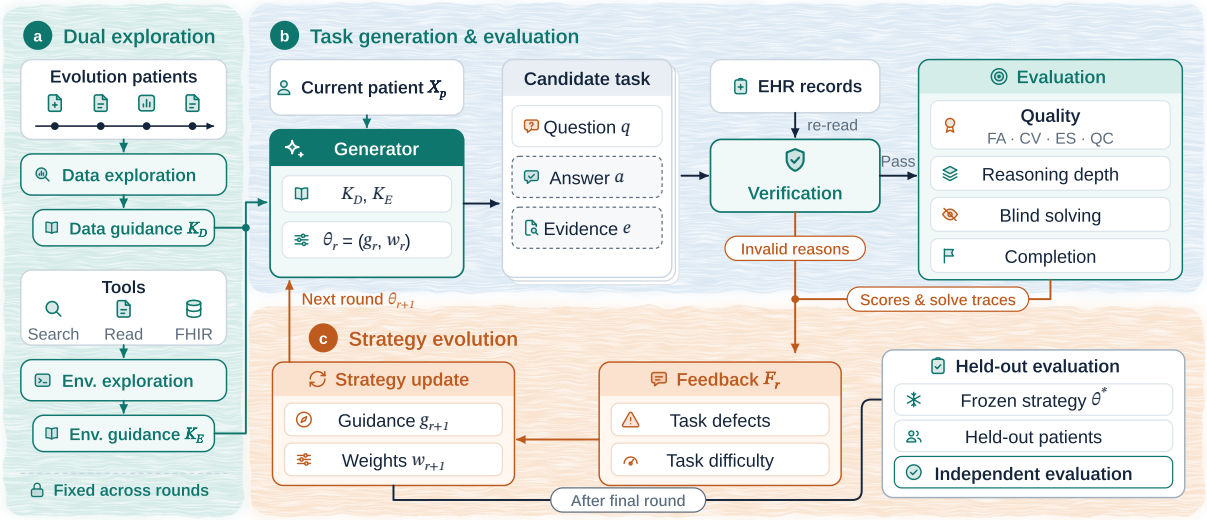


图 1. MedEvolve 方法概览。(a) 数据与环境双探索形成固定复用的指导 K_D 与 K_E。(b) 生成器结合患者轨迹、探索指导和当前策略构建任务，经原始记录核验后开展质量、推理深度、独立解题与完成评价；解题 Agent 不接收参考答案和证据声明。(c) 评价反馈修订生成指导与方向权重；进化结束后冻结策略，在留出患者上评测。

理难度，以及模型、工具或环境故障，以避免将执行异常当作任务难度。策略按下式更新：

$$\theta_{r+1} = \mathcal{U}(\theta_r, F_r), \tag{1}$$

其中 $\mathcal{U}$ 由 LLM 实现。更新作用于两个部分：一是把具有普遍性的构造经验写入 g_{r+1}，调整临床信息的选择、证据的组织和任务设计；二是根据各方向的质量与难度表现调整 w_{r+1}，改变后续任务的方向分布。

不同轮次使用不同的患者批次生成任务。完成预定轮次后冻结策略，并在独立的患者集上评测。

3 实验

3.1 评测条件与指标

环境与比较条件。实验覆盖 PhysicianBench 与 MedAgentBench，分别使用 108 与 100 位具有临床记录的患者，其中 81 与 75 位用于留出评测，其余用于策略进化，两组患者互不重叠。各方法共享留出患者与生成模型 GPT-5.4-nano，每位患者最多生成两道只读任务，固定请求题数分别为 162 与 150。患者划分与信息访问规则见附录 B。

评价指标。任务先对照原始记录核验，再由 GPT-4o-mini 与 GPT-5.4-nano 独立评价最小充分推理需求，聚合为 1–4 级。通过核验且层级不低于 3 的任务计为高阶题。主要指标为高阶题数及其占固定请求题数的比例，即有效高阶产出率，生成失败和无效任务造成的损失均计入；全部通过核验且具有难度评分的任务的平均层级作为辅助指标。评分与聚合细则见附录 D。

3.2 实验一：有效高阶题生成

我们比较不同生成方式能否在相同患者和题数上限下产出更多有效高阶任务。SingleShot 单次生成任务，Workflow 采用定位、生成与筛选流程，SelfRefine 通过自反馈修订候选，TaskCraft 通过深度与宽度扩展提高复杂度。EnvExplore 使用环境探索指导与固定初始策略；MedEvolve 则结合数据与环境双探索，使用两轮反馈更新后的完整策略。各方法的调用与计算投入不同，比较限定于共同患者和题数上限；具体流程与预算见附录 C。

表 1 显示，MedEvolve 在两个环境中的有效高阶产出率均最高，但相对最接近的 EnvExplore，其优势随环境变化：MedAgentBench 上多产出 13 道高阶题，产出率高出 8.6 个百分点；PhysicianBench 上仅多出 2 道，高出 1.2 个百分点。因此，结果支持完整框架在本次评测中的产出优势，但 PhysicianBench 上的差距较小。

核验通过率与高阶产出反映不同的任务特性。TaskCraft 的有效题平均层级接近 1，未产出高阶题；MedEvolve 的核验通过率低于部分基线，却保留了最多的有效高阶题（附录 F），说明仅考察核验通过率不足以评价生成任务的推理要求。平均层级也需结合样本量解读：PhysicianBench 上 Workflow 的均值略高于 MedEvolve（2.30 对 2.27），但仅基于 10 道通过核验的任务。

方法	PhysicianBench		MedAgentBench	
	高阶题数（产出率）	平均层级	高阶题数（产出率）	平均层级
MedEvolve	**23（14.2%）**	2.27	**77（51.3%）**	**2.73**
EnvExplore	21（13.0%）	2.25	64（42.7%）	2.56
TaskCraft	0（0.0%）	1.01	0（0.0%）	1.00
Workflow	3（1.9%）	**2.30**	2（1.3%）	2.67
SingleShot	3（1.9%）	1.20	11（7.3%）	1.44
SelfRefine	4（2.5%）	2.20	2（1.3%）	2.00

表 1. 有效高阶任务产出比较（生成模型：GPT-5.4-nano）。高阶题通过证据核验且聚合层级不低于 3；括号内为产出率，以固定请求题数为分母（PhysicianBench：162；MedAgentBench：150）。平均层级基于全部通过核验且具有难度评分的任务。粗体表示各列最高值。

3.3 实验二：合成任务补充官方任务训练

我们进一步检验合成任务能否补充官方任务，改善经验学习后的测试表现。在 PhysicianBench 中，ACE、Reflexion（Shinn et al., 2023）与 OpenClaw 分别从两种训练设置中积累经验：“官方 20”使用 20 道官方任务；“官方＋合成 40”在同一批官方任务上增加 20 道通过核验的 MedEvolve 任务。两组使用同一执行模型 Qwen3.8-27B，固定模型参数，并在训练后冻结经验，在共同的 50 道官方测试任务上评测。参考答案仅用于评分；框架机制与复现设置见附录 E。

表 2. 官方任务训练加入合成任务前后的题目通过率。通过率以全部 50 道计划测试题为分母，表示严格的整题成功。ACE 的官方组与混合组分别有 48 与 50 题完成评分，其余框架均覆盖 50 题。

框架	官方 20	官方＋合成 40	差值
ACE	4.0%（2/50）	10.0%（5/50）	+6.0 pp
Reflexion	12.0%（6/50）	14.0%（7/50）	+2.0 pp
OpenClaw	24.0%（12/50）	20.0%（10/50）	−4.0 pp

补充合成任务后，ACE 与 Reflexion 的通过率分别提高 6.0 与 2.0 个百分点，OpenClaw 则下降 4.0 个百分点（表 2）。这说明合成任务在部分经验学习框架中具有潜在价值，但本次评测未呈现一致收益。不同框架采用不同的经验载体与更新机制，可能影响合成任务的利用效果，当前比较尚不能确定收益差异的原因。

4 结论

本文提出 MedEvolve，将数据探索与环境探索结合，使医疗 Agent 任务生成同时受到患者纵向病历内容和工具证据获取能力的约束，并利用核验与独立解题反馈跨患者更新生成指导和任务方向权重，整个过程不更新模型参数。

在 PhysicianBench 与 MedAgentBench 上，MedEvolve 在六种对比方法中均取得最高的有效高阶任务产出，分别产出 23 道与 77 道通过核验的高阶题。下游经验学习实验进一步呈现了合成任务在部分框架中的潜在价值：加入合成任务后，ACE 与 Reflexion 的官方测试通过率提高，OpenClaw 则下降，体现出框架间的收益差异。这些发现支持将双探索任务生成作为构建医疗 Agent 高阶任务的一种方法，并为研究合成任务与经验学习机制的适配关系提供了实证依据。

局限性（Limitations）

下游经验学习实验比较了 20 道官方任务与加入 20 道合成任务后的训练设置，任务数量和组成同时发生变化。等量官方任务及其他生成方法所产任务的对照，有助于进一步区分训练规模与合成任务特性的影响。当前下游结果来自 PhysicianBench 上的单种子、50 道测试题，收益的稳定性及其在其他环境中的表现仍需更多评测。

MedEvolve 的生成指导从特定环境的患者记录与工具接口中提炼，当前独立患者评测考察的是同一环境内的策略迁移。当医疗机构、记录结构或证据检索工具发生变化时，已有指导的适用性及所需调整尚未得到系统评价。

参考文献

Jiang, Yixing, et al. 2025. MedAgentBench: A Realistic Virtual EHR Environment to Benchmark Medical LLM Agents. arXiv:2501.14654.

Liu, Ruoqi, et al. 2026. PhysicianBench: Evaluating LLM Agents in Real-World EHR Environments. arXiv:2605.02240.

Shi, Dingfeng, et al. 2025. TaskCraft: Automated Generation of Agentic Tasks.

arXiv:2506.10055.

Mai, Shinji, et al. 2025. CuES: A Curiosity-driven and Environment-grounded Synthesis Framework for Agentic RL. arXiv:2512.01311.

Shinn, Noah, et al. 2023. Reflexion: Language Agents with Verbal Reinforcement Learning. arXiv:2303.11366.

Zhai, Yunpeng, et al. 2025. AgentEvolver: Towards Efficient Self-Evolving Agent System. arXiv:2511.10395.

Madaan, Aman, et al. 2023. Self-Refine: Iterative Refinement with Self-Feedback. arXiv:2303.17651.

Kassis, Timothy, Vinayak Agarwal, Yuhuan He, Darshil Patel, and Aubrey M. Brueckner. 2026. Scientific Agent Skills: A Library of Procedural Knowledge for Research Agents. https://doi.org/10.48550/arXiv.2609.00065.

A 探索与生成接口

A.1 数据探索

探索工具提供开放患者名单、预算内轨迹及可选压缩摘要。输入材料保留患者标识、原始来源和覆盖标记，输出为不绑定患者的自然语言指导。指导归纳数据组织、时间变化、事件关系、证据引用与可支持的问题，不保留个体临床值或来源编号。

压缩摘要用于定位模式，原始记录用于支持具体事实。记录缺失与材料裁剪分别解释。指导中的时间窗口、记录数量或临床关系属于模型归纳的提问约束，不构成对所有患者统一适用的硬编码医学规则。

A.2 环境探索

环境探索在独立实例中访问开放患者的原生只读工具。指导记录已验证参数、返回结构、分页与裁剪行为、典型检索方式，并区分调用失败和未验证能力。环境内的具体患者观察不进入通用指导。

A.3 指导修订实例

A.4 任务生成与策略

任务包含患者标识、临床题型、问题、候选参考答案、来源标识与逐来源事实声明，以及执行要求；当前公共生成接口要求时间视角字段为空，执行要求为只读。生成调用输入预算内轨迹、两类探索指导、当前生成指导和两个采样方向，输出最多两题。

生成策略由自然语言指导和方向列表组成；方向包含五类临床题型之一、难度描述与非负权重。方向按权重采样，允许同一题型对应不同临床模式；至少一个权重为正。数据与环境指导在策略更新期间固定，更新只修订生成指导和方向列表。进化与评测阶段均按当前方向权重抽样，评测阶段使用冻结后的完整策略，即生成指导与方向权重。

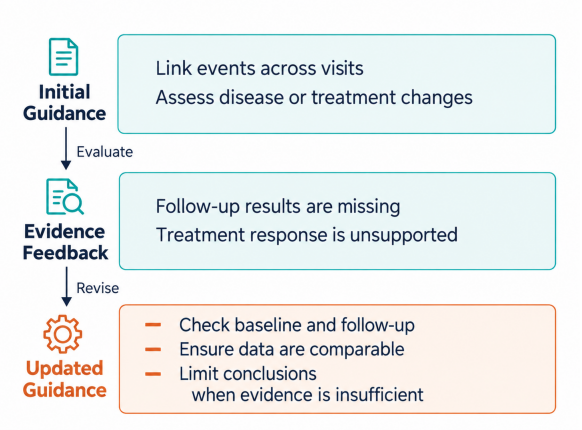


图 2. 一次策略自进化中的指导修订。核验反馈指出随访证据不足，更新后的指导增加基线、随访与数据可比性检查，并限定证据不足时的结论。图中文字根据一次进化记录概括。

表 3. 生成侧患者划分。

环境	患者总数	进化集	评测集	两轮进化患者数
PhysicianBench	108	27	81	13 / 14
MedAgentBench	100	25	75	12 / 13

B 环境、患者与信息访问

PhysicianBench 的生成患者池为 108 人，MedAgentBench 为官方范围内的 100 人。按种子 42 和既有探索暴露约束冻结进化与评测名单。进化患者分为互不重叠的两轮：PhysicianBench 为 13 与 14 人，MedAgentBench 为 12 与 13 人；评测患者分别为 81 与 75 人。

原始轨迹按记录时间组织，模型输入按预算选取；证据核验读取原始来源，不以输入摘要替代来源。初始探索和任务生成只开放查询工具。解题工具依环境与任务执行要求提供，经验训练的合成任务进一步限定为只读。当前公共生成接口未启用时间视角属性，问题中的时间限定不等同于服务端隐藏后续记录。

实验二的训练任务为 20 道官方任务加 20 道通过核验的合成任务，测试任务为共同的 50 道官方任务，该划分与生成侧患者划分相互独立。冻结清单记录选中题目、患者、训练与测试划分、文件摘要及生成来源。

C 生成方法与预算

TaskCraft 将患者记录与只读 FHIR 工具映射到原方法的结论抽取、原子任务生成、核验与扩展流程。深度和宽度分支均从原子任务出发，彼此没有先后依赖；两条分支共享生成总预算。原子、深度和宽度候选的实际产量及接纳情况分别记录，以区分扩展机制和最终筛选的影响。医疗适配与原论文完整实验复现分别解释。

Workflow 固定执行定位、生成和内部检查，检查只筛选候选。SingleShot 根据轨迹单次生成最多两题。SelfRefine 在同一患者批次内执行初稿、自反馈和修订，最多三次自评、两次修订，全部通过时提前结束。EnvExplore 先获取环境指导，再用固定初始策略生成任务。各方法共享输出结构和公共评价，内部调用与筛选记录分别保存。

主方法初始探索完成后执行两轮生成侧策略进化，每轮按患者归纳反馈并汇总更新。批次输出的结构或配额校验失败保留为生成失败。反馈和更新调用失败不视为进化成功。输入裁剪、实际调用与预算耗尽分别记录。

模型路由、上下文上限、输出限制和工具预算以冻结运行配置为准。同一比较中报告各方法预算与实际用量；相同出题数量不表述为严格相同 token 预算。探索和更新计入主方法总成本，公共评价成本单列，历史复用调用按原始记录去重计数。

D 评分与指标

D.1 推理层级

推理层级依据问题要求及证据结构标注：第 1 级直接读取事实，第 2 级结合记录与临床知识完成单步判断，第 3 级跨记录比较或整合信息，第 4 级综合证据权衡风险收益并提出方案。评分依据完成任务所需的最小充分推理路径；证据数量、时间跨度、答案长度或信息缺失本身不自动提高层级。临床题型与推理层级分别记录，不把治疗规划题自动判为最高层级。

难度裁判分别为 GPT-4o-mini 与 GPT-5.4-nano。对任务 i，两个裁判模型给出的原始层级为 $l_i^{(1)}$ 与 $l_i^{(2)}$，聚合层级为

$$l_i = \left\lfloor \text{median}\left(l_i^{(1)}, l_i^{(2)}\right) \right\rfloor .$$

聚合层级不低于 3 且通过核验的任务记为高阶题。正式协议要求两份有效输出，不以单个成功裁判替代缺失评价，原始层级与理由保留用于分歧分析。

D.2 指标与分母

生成失败和无效任务保留在产出统计中，不从分母中剔除。实验二的评分故障保留为覆盖不足，不转换为失败或成功。

E 经验学习与官方评测

两种训练设置各自独立保存配置和经验，从统一初始状态开始。Reflexion 的跨任务经验提炼为医疗适配：保存适用条件、操作步骤和错误教训，不保存患者标识、个体临床值或逐题答案；新题按冻结规则读取最多三条相关经验。测试不根据评分进行反思或重试。

执行模型为 Qwen3.8-27B，关闭思考，模型调用预算为 100，种子为 42。官方 20 题是两种训练设置共用的训练任务；混合设置另加入 20 道通过核验的 MedEvolve 合成任务，由 GPT-4o-mini 与 GPT-5.4-nano 各生成 10 道。

PhysicianBench 使用官方任务和检查点评分，提供实际文件交付、执行轨迹和本题 FHIR 实例；官方资产缺失或评分故障保留为不可用结果，不以公共模型裁判替代原生分数。参考答案只用于评分，不提供给执行与学习过程。

测试评分与解题隔离，评分完成前保留实际使用的医疗实例。每题使用冻结经验副本，不将参考答案、评分结果或完整会话回写到最终经验。测试前后核对冻结经验摘要，报告计划任务数与评分覆盖。

F 生成与核验数量

† PhysicianBench 上 EnvExplore 的数量来自冻结的旧批次，与表 1 中 21 道高阶题所在的最新运行不是同一批，不能作为这 21 题的分母。

G 写作辅助工具

中文稿的结构组织、方法描述核对与证据状态检查使用 Scientific Agent Skills 的 scientific-writing 技能（Kassis et al., 2026）辅助。文献与科学结论的最终核验由作者负责。

表 4. 指标定义与分母。

指标	分子	分母
高阶题数	通过核验且聚合层级不低于 3 的题数	—
高阶产出率	高阶题数	固定请求题数
有效题平均层级	通过核验且具有难度评分的题目的层级之和	通过核验且具有难度评分的题数
核验通过率	核验通过题数	实际生成题数
题目通过率（实验二）	严格整题成功的测试题数	计划测试题数（50）

表 5. 三种框架的经验载体与更新机制。

框架	持久化经验	训练更新	测试状态
OpenClaw	技能与独立状态目录	原生 Skill Workshop，记录是否触发	读取冻结技能，关闭学习与后台维护
ACE	策略手册	Reflector 和 Curator 更新	只运行 Generator
Reflexion	反思与可迁移经验	失败反思及限定次数重试	只运行 Actor，读取经验

表 6. 各方法的生成与核验数量（生成模型：GPT-5.4-nano，冻结旧批次）。分数为实际生成题数 / 核验通过题数；通过率为核验通过题数除以实际生成题数。

方法	PhysicianBench 生成 / 通过	通过率	MedAgentBench 生成 / 通过	通过率
MedEvolve	157 / 70	44.6%	146 / 104	71.2%
TaskCraft	128 / 125	97.7%	111 / 108	97.3%
Workflow	32 / 10	31.3%	11 / 3	27.3%
SingleShot	162 / 122	75.3%	150 / 127	84.7%
SelfRefine	12 / 10	83.3%	7 / 6	85.7%
EnvExplore	149 / 107†	71.8%†	141 / 108	76.6%