MedEvolve：基于双探索的纵向医疗任务生成与策略自进化

摘要

在患者纵向病历中自动构建医疗 Agent 任务，需要识别当前病例能够支持的临床关系，并确保相关证据可通过环境工具检索。本文提出 MedEvolve，通过数据探索提炼临床事件模式，通过环境探索核查证据获取方式，两类指导共同约束问题、参考答案与来源证据的生成。系统结合原始记录核验与独立解题反馈，跨患者批次修订生成指导并更新任务方向权重，推动生成策略自进化。研究在 PhysicianBench 与 MedAgentBench 中比较有效产出、任务质量和推理要求，并在共同官方任务上评价下游经验学习；任务生成实验覆盖两个环境、两个生成模型和六种方法；固定独立患者评测显示，策略更新的效果随环境与模型变化，未观察到一致的有效产量改善。下游经验学习按评分覆盖与原生学习触发状态报告，组件消融尚未执行。

1 引言

纵向病历记录了患者跨多次就诊的诊断、检验、用药和其他临床事件，是构建电子健康记录（EHR）Agent 任务的主要数据来源，MedAgentBench（Jiang et al., 2025）和 PhysicianBench（Liu et al., 2026）即在此类环境中评测 LLM Agent。此类任务通常需要临床专业人员参与设计与核对，难以大规模扩充。自动任务合成方面，TaskCraft（Shi et al., 2025）从网页、PDF、图像等数据出发生成任务，并通过深度和宽度扩展提高任务复杂度；CuES（Mai et al., 2025）则依靠与环境的交互探索合成任务，实验涉及 AppWorld、WebShop 和 BFCL。这两项工作都没有针对电子病历的纵向结构，以及任务证据必须能通过只读工具检索这一约束进行设计。

在纵向病历上自动构建任务有两个具体困难。第一，任务能否成立取决于病例记录和环境工具两方面。生成器读取当前患者的轨迹时，只能看到该患者拥有哪些记录，看不到同一数据源中哪些临床关系反复出现、各类问题的证据通常分布在哪些资源中，而完整轨迹本身也可能超出模型的输入预算。例如，包含多次检验结果的病例可支持趋势分析类问题，以诊断记录为主的病例则更适合临床解释类问题。同时，问题所需的证据还必须能够通过环境提供的工具检索到，这需要通过实际调用工具来了解。第二，固定的生成指导在不同病例上产出的任务质量和难度并不稳定，其缺陷往往要到证据核验或 Agent 实际解题之后才会暴露。

针对这两点，我们提出 MedEvolve。生成之前，数据探索从纵向记录中归纳可复用的临床事件模式，环境探索通过调用只读工具核查证据的获取方式，两者共同约束问题、参考答案和来源证据的生成。生成之后，系统对照原始记录核验证据声明，并由独立 Agent 解题，再把核验缺陷、质量与推理评分和解题轨迹汇总为反馈，跨患者批次修订自然语言生成指导，并调整不同任务方向的采样权重。整个过程不更新模型参数。

本文的贡献包括：（1）将数据探索与环境探索结合，使任务生成同时受病例内容和工具能力约束；（2）利用核验与解题反馈，在不更新模型参数的条件下跨患者更新生成策略；（3）给出覆盖有效产出、质量、推理要求和下游经验学习的评价协议，并在两个 EHR Agent 环境中检验上述机制。

2 方法

2.1 问题设置

给定医疗环境 $\mathcal{E}$ 和纵向患者轨迹集合 $\mathcal{D} = \{X_p\}$，目标是为每条轨迹 X_p 构造医疗 Agent 任务。每个任务由指令 q、候选参考答案 a 和来源证据 e 组成。生成过程由策略 $\theta_r = (g_r, w_r)$ 控制：g_r 是自然语言生成指导，w_r 是任务类型和难度方向的采样权重，r 为进化轮次。MedEvolve 先通过探索得到数据指导 K_D 与环境指导 K_E，再利用评价反馈更新 θ_r。

2.2 数据探索与环境探索

单个患者的轨迹只说明该病例包含哪些记录，难以判断这些记录在整个数据源中属于何种模式，也无法在每次生成时重复读取大量患者。因此，我们在生成之前先进行数据探索，把跨患者的观察整理为可复用的指导。

数据探索针对纵向患者轨迹。探索 Agent 读取多位患者的记录，分析数据的组织方式、时间变化、临床事件之间的关联和证据分布，归纳出不同类型任务所需的信息模式，形成数据指导 K_D。K_D 只描述可复用的模式，不包含特定患者的临床事实。

环境探索针对环境接口。探索 Agent 实际调用只读查询工具，记录访问方式、返回结构和交互约束，形成环境指导 K_E，用于判断一个问题所需的证据能否通过工具获取。

两类探索在初始化阶段完成，之后的所有轮次中保持不变。

2.3 任务生成与评价

对于患者 X_p，生成器以 K_D、K_E 和当前策略 θ_r 为条件，按指定的任务类型和难度方向生成 (q, a, e)，其中关键事实附带对原始记录的引用。

候选任务随后依次经过核验、评分和独立解题。核验重新读取原始记录，检查证据声明对参考答案的支持；通过核验的任务再接受任务质量和推理深度的评价，并由固定的 Agent 在环境中独立作答。解题 Agent 无法获得参考答案和证据声明。

2.4 反馈驱动的策略更新

每轮结束后，系统汇总该轮任务的核验缺陷、质量与推理评分以及解题轨迹，归因得到反馈 F_r。归因需要区分任务本身的缺陷（如事实错误、证据不足、题意歧义）、任务带来的真实推理难度，以及模型、工具或环境故障，以避免将执行异常当作任务难度。策略按下式更新：

$$\theta_{r+1} = \mathcal{U}(\theta_r, F_r), \tag{1}$$

其中 $\mathcal{U}$ 由 LLM 实现。更新作用于两个部分：一是把具有普遍性的构造经验写入 g_{r+1}，调整临床信息的选择、证据的组织和任务设计；二是根据各方向的质量与难度表现调整 w_{r+1}，改变后续任务的方向分布。

不同轮次使用不同的患者批次生成任务。完成预定轮次后冻结策略，并在独立的患者集上评测。

3 实验设置

3.1 环境与对比方法

研究覆盖 PhysicianBench 与 MedAgentBench，生成患者池分别为 108 与 100 人。已有配置分别将 27 与 25 人用于进化、81 与 75 人用于独立评测，种子为 42，历史探索患者保留在进化集。患者不跨集合，独立评测不参与策略更新。已有运行采用两轮，下述四轮分析需另行冻结患者分批。完整划分及信息访问规则见附录 B。

生成比较分别使用 GPT-5.4-nano 与 GPT-4o-mini，独立解题采用对应模型。各方法每患者最多生成两道只读任务，回顾性访问完整时间范围，共享评测患者与公共评价。TaskCraft 采用原子生成和深度 / 宽度扩展；Workflow 采用定位、生成与筛选；SingleShot 单次生成；SelfRefine 在患者批次内反馈修订（Madaan et al., 2023）；EnvExplore 使用环境指导和固定初始策略；MedEvolve 使用双探索和跨患者更新。各方法内部选择规则与调用流程见附录 C。

独立评测固定初始方向列表和抽样种子，读取当前策略的生成指导，以控制方向构成并检验指导更新，不将其解释为指导与权重更新的整体效果。相同题数上限不代表相同计算投入：生成成本包含探索、内部检查、反馈与更新，公共评价成本单列。

3.2 评价协议

核验与完成裁判采用 GPT-5.4-nano；质量和难度分别由 GPT-5.4-nano 与 GPT-4o-mini 独立评价，对两份有效输出取中位数并向下取整，保留原始评分与理由。质量从事实准确性、临床合理性、证据充分性和题目清晰度给出 1–5 分。推理分为事实查询、单步推理、整合推理和临床决策四级，3–4 级记为高阶，题型不直接决定推理层级。

评价报告请求与实际生成量、核验覆盖与通过量、评分覆盖、质量均值和高阶题数。核验通过率以具有核验结果的任务为分母，质量仅统计核验通过且评分有效的任务。完成率分别以生成任务和具有完成评价的任务为分母。引用来源数、资源类型数和时间跨度描述证据结构，评价缺失与运行故障分别统计。

统计方案按患者簇进行 1,000 次重采样，种子为 42，以分位数构造 95% 区间。同一患者的任务共同进入样本，方法与检查点比较保持患者配对，并报告评价覆盖及有效重采样次数。各阶段记录调用与输入、输出 token，生成成本另按通过题数归一化，未知用量保留缺失。评分尺度、分母与汇总规则见附录 D。

4 结果与分析

4.1 有效产出、质量与推理要求

表 1 按环境与生成模型共同报告产出、质量和高阶任务。PhysicianBench 与 MedAgentBench 分别覆盖 81 和 75 位独立评价患者，每位患者最多生成两题；生成失败和无效任务保留在产出统计中。图 1 展示 PhysicianBench、GPT-4o-mini 条件的核验状态与推理层级，其余条件和质量区间见附录 F。

TaskCraft 在四个条件下的核验通过率为 88.2

4.2 策略自进化

实验比较初始策略与四轮更新后的策略，共五个检查点。各检查点在同一独立患者集上生成并评价，固定探索指导、模型、初始方向配比、种子、题数上限和公共评价，独立成绩不参与更新。四轮使用不同进化患者批次，每位患者的生成与评价预算一致。PhysicianBench 四轮患者数为 6、7、7、7，MedAgentBench 为 6、6、6、7；五个检查点的独立评测正在进行。

图 2 分别展示四维质量、核验通过率和高阶有效题数。通过率以具有核验结果的任务为分母，高阶有效题需通过核验且被标为 3–4 级。曲线附患者簇区间及评分、核验覆盖；不同训练批次上的成绩不替代固定患者上的策略比较。

MedAgentBench、gpt-4o-mini 的核验通过率由 11.0% 变为 6.7%，高阶有效题数由 12 变为 10。MedAgentBench、gpt-5.4-nano 的核验通过率由 80.7% 变为 71.7%，高阶有效题数由 95 变为 78。PhysicianBench、gpt-4o-mini 的核验通过率由 13.8% 变为 18.5%，高阶有效题数由 16 变为 14。PhysicianBench、gpt-5.4-nano 的核验通过率由 72.4% 变为 73.8%，高阶有效题数由 93 变为 99。不同完整条件的核验量与高阶任务量变化方向不完全一致；更新策略并不保证独立效果提高。完整曲线见附录 F。

4.3 组件消融

表 2 比较完整 MedEvolve、去数据探索、去环境探索和关闭反馈更新。每组保留其余组件；关闭更新组保留双探索和初始指导，在相同进化批次上生成与评价，但不修订策略。各组固定独立患者、模型、初始方向配比、种子、题数上限和公共评价。

四轮结束后比较核验通过量、独立质量维度、高阶有效量和实际生成 token。质量仅统计通过核验且评分有效的任务，关闭更新组节省的反馈与更新调用计入成本差异。EnvExplore 在主实验中作为组合对照，不用于单独归因某个组件。正式消融结果尚未填入。

4.4 下游经验学习

PhysicianBench 下游实验将六种任务来源分别接入 OpenClaw、ACE 和 Reflexion（Shinn et al., 2023），并将 MedEvolve 接入 Hermes Agent，共 19 个来源与 Harness 组合。MedEvolve 的四个基座均使用主实验中生成并通过核验的任务。模型权重固定，来源在同一 Harness 内相对统一初始状态比较。各来源选取相同数量的核验通过只读任务，不超过最小有效产量；以种子 42 按任务划分 70% 训练、30% 辅助测试，训练数向下取整。PhysicianBench 冻结配置每来源 25 题（17 训练、8 测试），使用 GPT-4o-mini、训练一轮；其他环境以冻结清单为准。

表 1. 主实验生成比较。通过率以具有核验结果的任务为分母；质量题数为评分覆盖。FA、CV、ES、QC 依次表示事实准确性、临床合理性、证据充分性和题目清晰度（1–5 分）；HO 为高阶有效题数 / 具有难度评分的题数。

方法	生成数	通过数	通过率	质量题数	FA	CV	ES	QC	HO
PhysicianBench / gpt-4o-mini									
MedEvolve	161	32	19.9%	32	4.16	3.84	3.62	4.56	16/32
TaskCraft	119	105	88.2%	105	4.93	4.50	4.89	4.91	0/105
Workflow	139	25	18.0%	25	4.08	3.84	3.76	4.76	15/25
SingleShot	162	86	53.1%	86	4.42	4.23	4.14	4.87	10/86
SelfRefine	101	26	25.7%	26	3.96	4.00	3.58	4.38	12/26
EnvExplore	160	27	16.9%	27	4.04	3.96	3.52	4.74	14/27
MedAgentBench / gpt-4o-mini									
MedEvolve	150	30	20.0%	30	4.17	3.90	3.63	4.83	21/30
TaskCraft	108	102	94.4%	102	4.91	4.40	4.93	4.90	0/102
Workflow	103	23	22.3%	23	3.87	3.87	3.57	4.57	18/23
SingleShot	150	76	50.7%	76	4.39	4.16	4.08	4.70	16/76
SelfRefine	111	19	17.1%	19	3.84	3.84	3.53	4.74	9/19
EnvExplore	141	26	18.4%	26	4.04	3.92	3.65	4.65	16/26
PhysicianBench / gpt-5.4-nano									
MedEvolve	157	70	44.6%	69	4.35	4.17	3.94	4.93	52/69
TaskCraft	128	125	97.7%	125	4.96	4.73	4.96	4.98	0/125
Workflow	32	10	31.2%	10	4.60	4.30	4.20	5.00	7/10
SingleShot	162	122	75.3%	122	4.68	4.48	4.55	4.93	20/122
SelfRefine	12	10	83.3%	10	4.90	4.10	4.80	4.90	4/10
EnvExplore	149	107	71.8%	107	4.43	4.20	4.13	4.93	86/107
MedAgentBench / gpt-5.4-nano									
MedEvolve	146	104	71.2%	102	4.16	4.17	3.87	4.94	90/101
TaskCraft	111	108	97.3%	108	4.94	4.67	4.94	4.94	0/108
Workflow	11	3	27.3%	3	4.33	4.33	4.00	5.00	3/3
SingleShot	150	127	84.7%	127	4.61	4.27	4.54	4.93	35/127
SelfRefine	7	6	85.7%	6	4.50	4.33	4.83	5.00	3/6
EnvExplore	141	108	76.6%	108	4.38	4.15	4.08	4.93	95/108

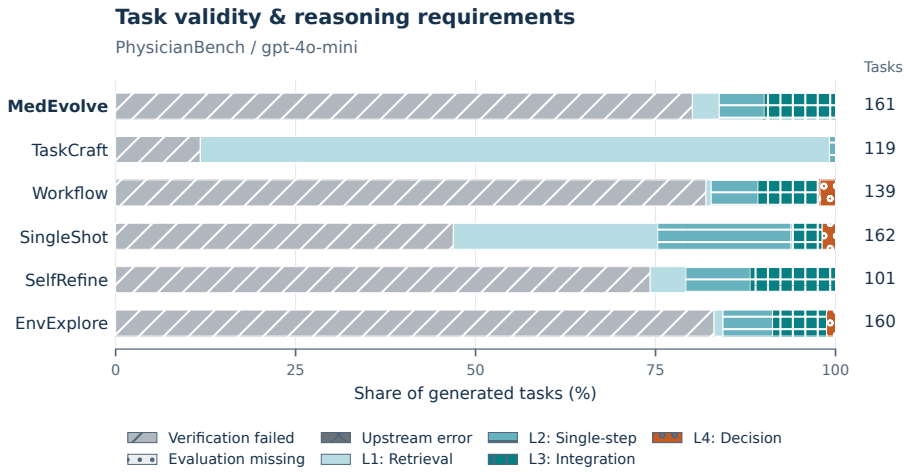


图 1. PhysicianBench、GPT-4o-mini 条件的生成任务核验状态与推理层级。横轴为占实际生成量的比例，右侧报告生成题数；四级推理要求仅针对核验通过任务。

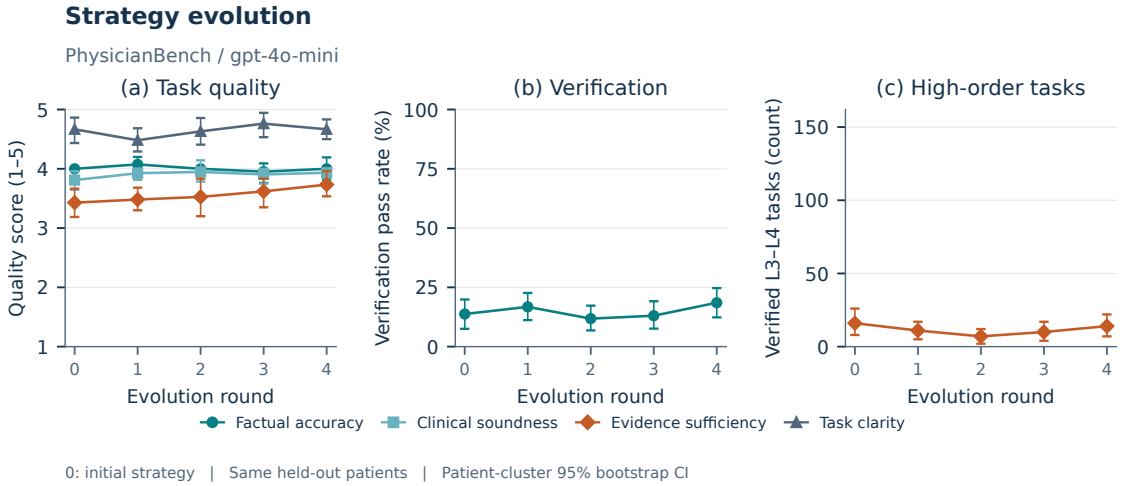


图 2. 固定独立患者集上的策略自进化。0 为初始策略，1–4 为逐轮更新后的策略。(a) 核验通过任务的四维质量均值；(b) 公共核验通过率；(c) 核验通过且推理层级为 3–4 的任务数。PhysicianBench、GPT-4o-mini 条件的五个检查点均覆盖相同 81 位独立患者。质量评分题数依次为 21、27、19、21、30，核验通过题数依次为 22、27、19、21、30。区间为患者簇 95% 重采样区间。

表 2. 四组组件消融。四维质量依次为事实准确性、临床合理性、证据充分性和题目清晰度（1–5 分）。正式结果附患者簇区间和覆盖，并按环境与生成模型分别报告。

配置	核验通过题数	四维质量	高阶有效题数	生成 token
完整 MedEvolve	—	—/—/—/—	—	—
去数据探索	—	—/—/—/—	—	—
去环境探索	—	—/—/—/—	—	—
关闭反馈更新	—	—/—/—/—	—	—

训练每题使用新会话和医疗实例，答案与证据仅在执行后供评审与学习，跨题保留技能、记忆或策略手册。训练结束后冻结经验，不按测试成绩选版本。测试关闭写入和后台学习，每题从冻结快照及独立会话、实例开始。各 Harness 的机制与限制见附录 E。

ace / MedEvolve 的成功题数为 0/0，有效评分覆盖为 98/93，有效配对 92 题。ace / SingleShot 的成功题数为 0/0，有效评分覆盖为 100/97，有效配对 97 题。ace / TaskCraft 的成功题数为 0/0，有效评分覆盖为 99/95，有效配对 94 题。ace / Workflow 的成功题数为 0/0，有

表 3. PhysicianBench 共同 100 题上的下游记录。成功率以计划 100 题为分母；检查点得分仅统计初始与最终均有评分的同题配对。区间为同题患者簇重采样区间。执行故障保留在覆盖中，覆盖不足的组不能作为完整进化比较。

基座	任务来源	成功率初始/最终%	提升百分点 [95% 区间]	有效评分初始/最终	配对检查点得分初始/最终%
ace	MedEvolve	0.0 / 0.0	0.0 [0.0,0.0]	98 / 93	5.38 / 5.84
openclaw	MedEvolve	运行中	—	—	—
reflexion	MedEvolve	0.0 / 0.0	0.0 [0.0,0.0]	87 / 75	1.25 / 0.98
hermes	MedEvolve	运行中	—	—	—
ace	TaskCraft	0.0 / 0.0	0.0 [0.0,0.0]	99 / 95	5.41 / 8.11
openclaw	TaskCraft	0.0 / 0.0	0.0 [0.0,0.0]	99 / 97	9.36 / 10.35
reflexion	TaskCraft	0.0 / 0.0	0.0 [0.0,0.0]	86 / 88	2.01 / 1.74
ace	Workflow	0.0 / 0.0	0.0 [0.0,0.0]	99 / 96	5.65 / 5.87
openclaw	Workflow	0.0 / 0.0	0.0 [0.0,0.0]	99 / 98	11.36 / 11.59
reflexion	Workflow	运行中	—	—	—
ace	SingleShot	0.0 / 0.0	0.0 [0.0,0.0]	100 / 97	4.76 / 7.76
openclaw	SingleShot	0.0 / 0.0	0.0 [0.0,0.0]	97 / 98	12.46 / 8.47
reflexion	SingleShot	运行中	—	—	—
ace	SelfRefine	运行中	—	—	—
openclaw	SelfRefine	运行中	—	—	—
reflexion	SelfRefine	运行中	—	—	—
ace	EnvExplore	运行中	—	—	—
openclaw	EnvExplore	运行中	—	—	—
reflexion	EnvExplore	运行中	—	—	—

效评分覆盖为 99/96，有效配对 96 题。openclaw / SingleShot 的成功题数为 0/0，有效评分覆盖为 97/98，有效配对 95 题。openclaw / TaskCraft 的成功题数为 0/0，有效评分覆盖为 99/97，有效配对 96 题。openclaw / Workflow 的成功题数为 0/0，有效评分覆盖为 99/98，有效配对 97 题。reflexion / MedEvolve 的成功题数为 0/0，有效评分覆盖为 87/75，有效配对 63 题。reflexion / TaskCraft 的成功题数为 0/0，有效评分覆盖为 86/88，有效配对 74 题。执行和评分故障不等同于临床失败，覆盖不足的组不能作为完整进化比较。零提升及零宽区间不证明经验学习无效。OpenClaw 的 102 次训练会话均低于原生后台复盘 10 轮门槛，经验未更新。其余 10 组仍在运行；OpenClaw 历史认证故障记录正在补评。

MedEvolve 的 17 道训练题涉及 16 位患者，8 道辅助测试题涉及 6 位患者，训练与辅助测试的患者不重叠；这些患者均在 100 位官方评测患者中。四个基座使用完全相同的训练及辅助测试题目。下游结果适用于患者重叠条件下的任务迁移，需与未见患者的泛化评价区分。

主要评价使用共同官方任务与原生评分。对官方任务集 B 和经验状态 h，定义

$$A(h) = \frac{N_{\text{confirmed success}}(h)}{|B|},$$
$$\Delta_m = 100\big(A(h_m) - A(h_0)\big),$$

其中 h_0 与 h_m 为初始及来源训练后的状态。分子为有效评分确认成功的任务数，分母包含全部计划任务，执行和评分故障与临床失败分别报告。表 3 报告最终成功率和百分点变化，包括初始与最终均有效评分的同题配对变化。辅助合成测试只检验各来源自身分布，不用于跨来源排名，并记录患者重叠与题目近重复。

5 结论

MedEvolve 通过数据与环境双探索选择由当前病例支持的问题，再利用核验和解题反馈跨患者更新生成指导与方向权重。评价协议将有效任务构建与下游经验学习联系起来，任务生成实验显示，高核验通过率、高阶任务产出与生成覆盖需要联合评价；固定患者评测显示策略更新效果因环境与模型而异，不保证高阶有效产量提高；下游比较仍需结合评分覆盖和原生学习触发情况解释。

局限性（Limitations）

病例记录的完整性、时间信息和模型输入预算限制了可发现的提问模式，轨迹裁剪也可能遗漏关键依据。同一环境内的患者独立划分只能检验该环境中的迁移，跨机构或跨数据来源的泛化仍需另外评价。当前生成采用回顾性信息访问，不启用时间视角隔离，因此不代表临床当时可获得的信息范围。

这些数据限制也影响自动评价。两个模型的评分聚合不能消除共同偏差，现有记录未必足以判定所有临床方案；质量评分又仅覆盖核验通过且评分成功的任务，复杂任务可能因单

条引用失败而被整体拒绝。因此，评分均值需要结合评价覆盖和有效产量解释。

对策略自进化的解释同样受比较条件约束。独立评测固定方向配比，主要检验生成指导更新，未覆盖更新后方向分布的整体效果。反馈模型给出的归因和建议也可能有误，策略更新不保证后续结果单调改善。

下游实验中，合成训练与辅助测试按任务划分，可能共享患者，官方测试也可能与经验训练共享底层记录。当前单种子、单次训练配置不能衡量跨运行稳定性，患者簇重采样仅反映测试样本不确定性。不同 Harness 的原生学习触发和调用限制存在差异，任务来源的比较因而限定在同一 Harness 内。

参考文献

Jiang, Yixing, et al. 2025. MedAgentBench: A Realistic Virtual EHR Environment to Benchmark Medical LLM Agents. arXiv:2501.14654.

Liu, Ruoqi, et al. 2026. PhysicianBench: Evaluating LLM Agents in Real-World EHR Environments. arXiv:2605.02240.

Shi, Dingfeng, et al. 2025. TaskCraft: Automated Generation of Agentic Tasks. arXiv:2506.10055.

Mai, Shinji, et al. 2025. CuES: A Curiosity-driven and Environment-grounded Synthesis Framework for Agentic RL. arXiv:2512.01311.

Shinn, Noah, et al. 2023. Reflexion: Language Agents with Verbal Reinforcement Learning. arXiv:2303.11366.

Zhai, Yunpeng, et al. 2025. AgentEvolver: Towards Efficient Self-Evolving Agent System. arXiv:2511.10395.

Madaan, Aman, et al. 2023. Self-Refine: Iterative Refinement with Self-Feedback. arXiv:2303.17651.

Kassis, Timothy, Vinayak Agarwal, Yuhuan He, Darshil Patel, and Aubrey M. Brueckner. 2026. Scientific Agent Skills: A Library of Procedural Knowledge for Research Agents. https://doi.org/10.48550/arXiv.2609.00065.

A 探索与生成接口

A.1 数据探索

探索工具提供开放患者名单、预算内轨迹及可选压缩摘要。输入材料保留患者标识、原始来源和覆盖标记，输出为不绑定患者的自然语言指导。指导归纳数据组织、时间变化、事件关系、证据引用与可支持的问题，不保留个体临床值或来源编号。

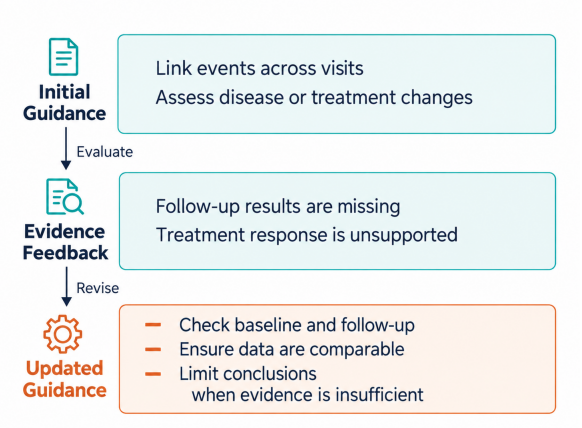


图 3. 一次策略自进化中的指导修订。核验反馈指出随访证据不足，更新后的指导增加基线、随访与数据可比性检查，并限定证据不足时的结论。图中文字根据一次进化记录概括。

压缩摘要用于定位模式，原始记录用于支持具体事实。记录缺失与材料裁剪分别解释。指导中的时间窗口、记录数量或临床关系属于模型归纳的提问约束，不构成对所有患者统一适用的硬编码医学规则。

A.2 环境探索

环境探索在独立实例中访问开放患者的原生只读工具。指导记录已验证参数、返回结构、分页与裁剪行为、典型检索方式，并区分调用失败和未验证能力。环境内的具体患者观察不进入通用指导。

A.3 指导修订实例

A.4 任务生成与策略

任务包含患者标识、临床题型、问题、候选参考答案、来源标识与逐来源事实声明，以及执行要求；当前公共生成接口要求时间视角字段为空，执行要求为只读。生成调用输入预算内轨迹、两类探索指导、当前生成指导和两个采样方向，输出最多两题。

生成策略由自然语言指导和方向列表组成；方向包含五类临床题型之一、难度描述与非负权重。方向按权重采样，允许同一题型对应不同临床模式；至少一个权重为正。数据与环境指导在策略更新期间固定，更新只修订生成指导和方向列表。进化阶段按当前方向权重抽样；独立评测固定初始方向列表与抽样种子，读取当前策略的生成指导。

B 环境、患者与信息访问

PhysicianBench 的生成患者池为 108 人，MedAgentBench 为官方范围内的 100 人。按种子 42 和既有探索暴露约束冻结进化与评测名单。进

表 4. 生成侧患者划分。

环境	患者总数	进化集	独立评测集	两轮进化患者数
PhysicianBench	108	27	81	13 / 14
MedAgentBench	100	25	75	12 / 13

化患者分为互不重叠的两轮：PhysicianBench 为 13 与 14 人，MedAgentBench 为 12 与 13 人；评测患者分别为 81 与 75 人。

原始轨迹按记录时间组织，模型输入按预算选取；证据核验读取原始来源，不以输入摘要替代来源。初始探索和任务生成只开放查询工具。解题工具依环境与任务执行要求提供，经验训练的合成任务进一步限定为只读。当前公共生成接口未启用时间视角属性，问题中的时间限定不等同于服务端隐藏后续记录。

经验学习另按合成任务划分训练与辅助测试，不能与生成侧患者划分混用。冻结清单记录选中题目、患者、训练与测试划分、文件摘要及生成来源。官方任务评测另记录任务版本、患者范围及与经验训练的重叠。

C 生成方法与预算

TaskCraft 将患者记录与只读 FHIR 工具映射到原方法的结论抽取、原子任务生成、核验与扩展流程。深度和宽度分支均从原子任务出发，彼此没有先后依赖；两条分支共享生成总预算。原子、深度和宽度候选的实际产量及接纳情况分别记录，以区分扩展机制和最终筛选的影响。医疗适配与原论文完整实验复现分别解释。

Workflow 固定执行定位、生成和内部检查，检查只筛选候选。SingleShot 根据轨迹单次生成最多两题。SelfRefine 在同一患者批次内执行初稿、自反馈和修订，最多三次自评、两次修订，全部通过时提前结束。EnvExplore 先获取环境指导，再用固定初始策略生成任务。各方法共享输出结构和公共评价，内部调用与筛选记录分别保存。

主方法初始探索完成后执行两轮生成侧策略进化，每轮按患者归纳反馈并汇总更新。批次输出的结构或配额校验失败保留为生成失败。反馈和更新调用失败不视为进化成功。输入裁剪、实际调用与预算耗尽分别记录。

模型路由、上下文上限、输出限制和工具预算以冻结运行配置为准。同一比较中报告各方法预算与实际用量；相同出题数量不表述为严格相同 token 预算。探索和更新计入主方法总成本，公共评价成本单列，历史复用调用按原始记录去重计数。

D 评分、汇总与统计

D.1 质量与推理深度

推理深度依据问题要求及证据结构标注：第 1 级直接读取事实，第 2 级结合记录与临床知识完成单步判断，第 3 级跨记录比较或整合信息，第 4 级综合证据权衡风险收益并提出方案。临床题型与推理层级分别记录，不把治疗规划题自动判为最高层级。

对任务 i、质量维度 d，两个模型的原始评分为 $s_{i,d}^{(1)}$ 与 $s_{i,d}^{(2)}$，最终评分为

$$s_{i,d} = \left\lfloor \text{median}\left(s_{i,d}^{(1)}, s_{i,d}^{(2)}\right) \right\rfloor .$$

难度采用同样聚合规则，保留两个原始层级与理由。正式协议要求两份有效输出，不以单个成功裁判替代缺失评价。质量评分材料包含题目、参考答案、证据、轨迹与核验结果；难度评分依据任务要求和自动复杂度。原始评分用于分歧分析。

D.2 证据结构与比率

对引用来源去重得到 S_i，证据数量为 $|S_i|$，资源类型数由可识别类型前缀去重得到。引用记录中可解析的时间集合为 T_i，其跨度为

$$\Delta_i = \frac{\max T_i - \min T_i}{1\ \text{天}}.$$

无可解析时间时记缺失，只有一个可解析时间时为零。报告时间可解析任务数，跨度分布和中位数仅使用非缺失值。

分母为零时记缺失。质量均值、层级分布和证据结构分别报告覆盖数。临床失败、证据不足、题意歧义、工具故障、环境故障与模型故障分别汇总，不由运行状态推断任务完成。

D.3 不确定性估计

统计方案以患者为簇，进行 1,000 次有放回重采样，种子为 42，取分布的 2.5% 与 97.5% 分位数作为 95% 区间。患者的全部题目共同进入样本，相同患者上的方法差异保留配对。重采样分母为零的指标记缺失，不转换为零；区间随指标有效重采样次数报告。

官方任务的初始与最终状态先按任务标识配对，再按患者簇重采样；共同任务和共同有

表 5. 四维质量评分标准。各维度独立评分。

分数	事实准确性	临床合理性	证据充分性	题目清晰度
5	数值、单位、药物、剂量与时间准确	推理严密，方案与风险考虑充分	关键事实和结论均有明确支持	目标、背景与操作要求明确
4	核心准确，存在次要细节瑕疵	基本合理，个别步骤有不足	主要结论有支持，细节引用不完整	基本清晰，个别细节需推断
3	多数准确，少量非关键错误	方向正确，但遗漏重要考虑	核心结论有支持，部分推理缺引用	方向明确，但缺关键背景
2	关键事实错误	有明显漏洞或违背常规实践	关键结论缺支持	目标模糊、矛盾或缺必要限定
1	多处严重错误或编造数据	推理错误或方案有明显风险	主要依赖未支持的推断或编造	无法理解或执行

表 6. 生成任务的比率分母。

指标	分子	分母
生成覆盖率	实际生成题数	请求题数
核验覆盖率	具有核验结果的题数	实际生成题数
核验通过率	核验通过题数	具有核验结果的题数
高阶题占比	深度为 3–4 的题数	具有难度评分的题数
维度高质量占比	该维度评分不低于 4 的题数	具有该维度评分的题数
全部生成任务完成率	判定完成题数	实际生成题数
已评价任务完成率	判定完成题数	具有完成评价的题数

表 7. 四种 Harness 的经验载体与更新机制。

Harness	持久化经验	训练更新	测试状态
OpenClaw	技能与独立状态目录	原生 Skill Workshop，记录是否触发	读取冻结技能，关闭学习与后台维护
Hermes Agent	技能与记忆	原生技能和记忆机制	保留读取，关闭写入与整理
ACE	策略手册	Reflector 和 Curator 更新	只运行 Generator
Reflexion	反思与可迁移经验	失败反思及限定次数重试	只运行 Actor，读取经验

效评分分别报告。单次训练结果不附跨训练标准差。

E 经验学习与官方评测

各组独立保存配置和经验，从统一初始状态开始。Reflexion 的跨任务经验提炼为医疗适配：保存适用条件、操作步骤和错误教训，不保存患者标识、个体临床值或逐题答案；新题按冻结规则读取最多三条相关经验。测试不根据评分进行反思或重试。

PhysicianBench 当前配置每来源 25 题，训练 17 题、辅助测试 8 题，训练一轮、种子 42。执行与经验更新使用 GPT-4o-mini，单题执行轮次上限 30、工具调用上限 200、执行超时 900 秒，学习轮次上限 10、超时 300 秒。各 Harness 采用原生可用限制，后台调用或原生组件内部用量无法完整计数时标为未知，不表述为统一硬预算拦截。

官方评测锁定任务与评分资产版本。PhysicianBench 使用官方任务和检查点评分，提供实际文件交付、执行轨迹和本题 FHIR 实例；任务成功率与平均检查点得分分别报告。MedAgentBench 按冻结配置选择任务版本并使用官方完成评判，版本间结果分别报告。官方资产缺失或评分故障保留为不可用结果，不以公共模型裁判替代原生分数。

测试评分与解题隔离，评分完成前保留实际使用的医疗实例。每题使用冻结经验副本，不将参考答案、评分结果或完整会话回写到最终经验。测试前后核对冻结经验摘要，报告计划任务数、评分覆盖、初始与最终成绩以及完整与配对口径的提升。

F 补充结果与案例

证据数量、资源类型和时间跨度描述支持任务的记录结构，不单独代表临床推理质量。经过作者核对的案例与下游辅助测试结果尚未报告。

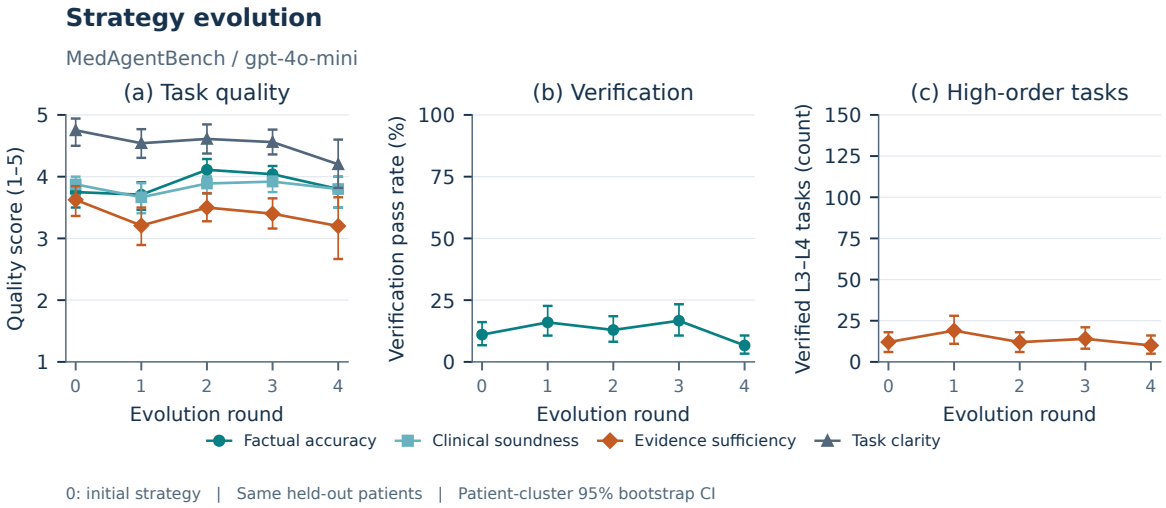


图 4. MedAgentBench、gpt-4o-mini 四轮策略更新的独立评测。已有 5/5 个完整检查点，使用相同患者集，固定初始方向配比；缺失检查点不连线，误差线为患者簇 95% 区间。

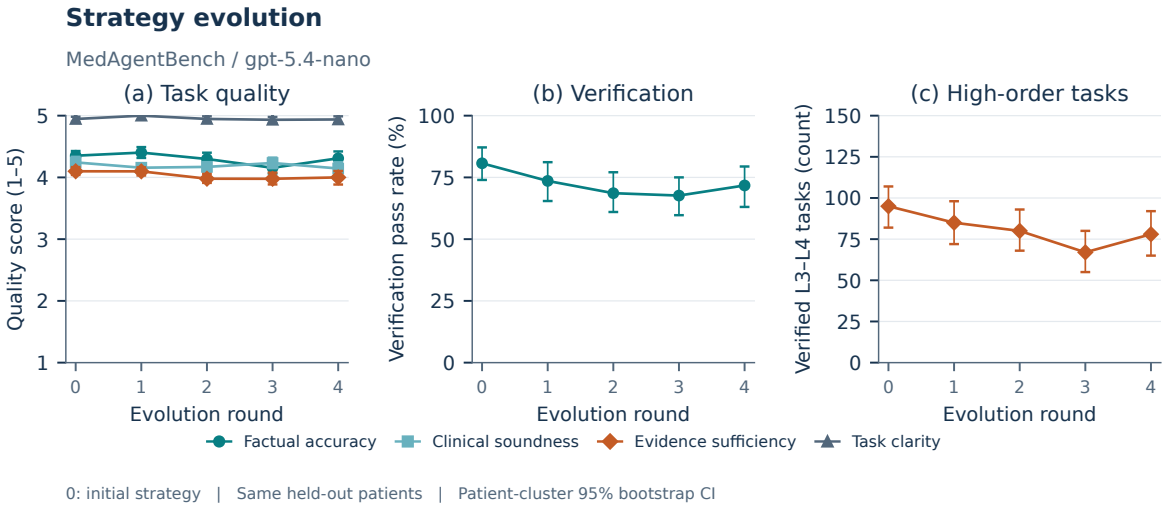


图 5. MedAgentBench、gpt-5.4-nano 四轮策略更新的独立评测。已有 5/5 个完整检查点，使用相同患者集，固定初始方向配比；缺失检查点不连线，误差线为患者簇 95% 区间。

G 写作辅助工具

中文稿的结构组织、方法描述核对与证据状态检查使用 Scientific Agent Skills 的 scientific-writing 技能（Kassis et al., 2026）辅助。文献与科学结论的最终核验由作者负责。

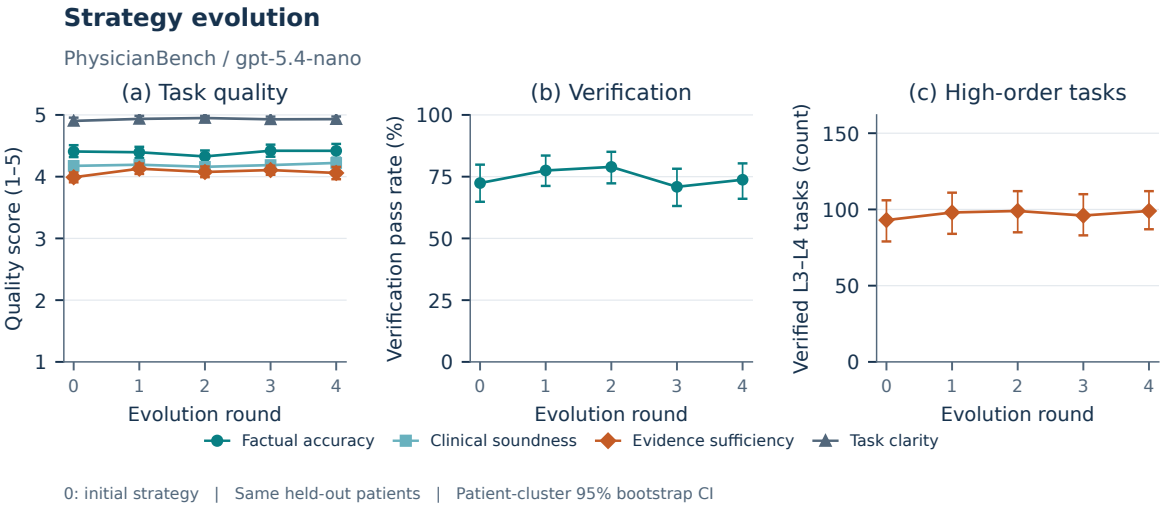


图 6. PhysicianBench、gpt-5.4-nano 四轮策略更新的独立评测。已有 5/5 个完整检查点，使用相同患者集，固定初始方向配比；缺失检查点不连线，误差线为患者簇 95% 区间。

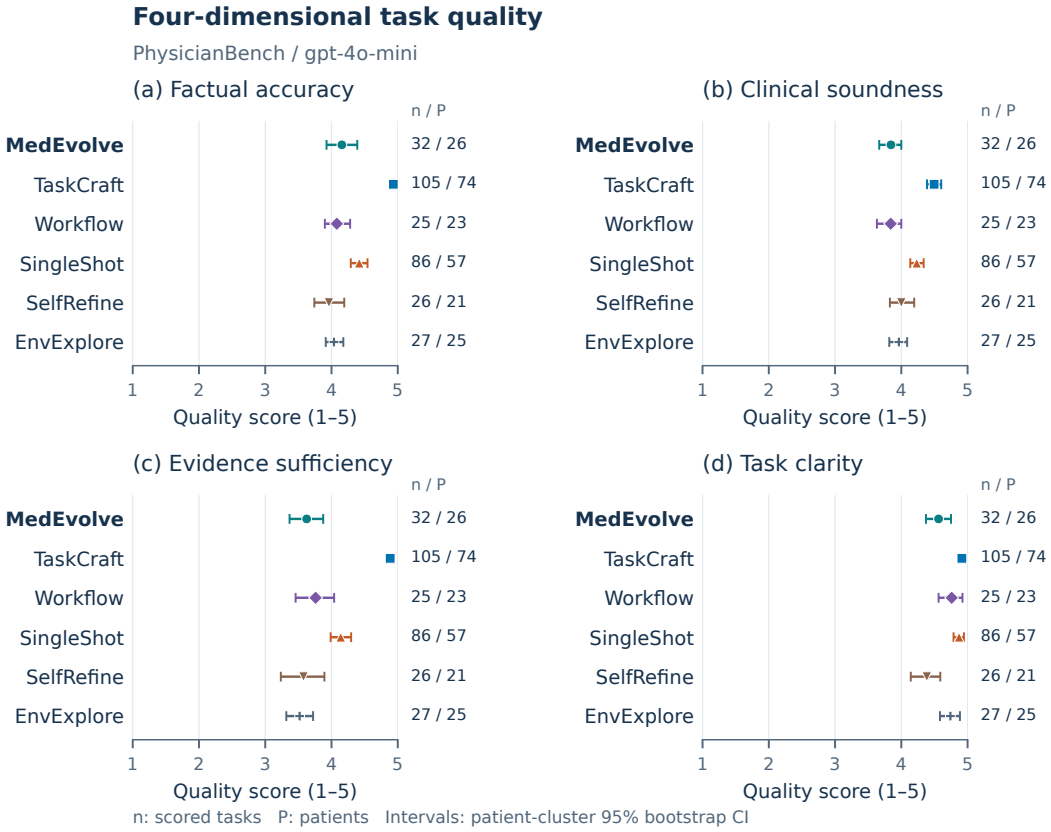


图 7. PhysicianBench、gpt-4o-mini 条件的四维质量。仅统计核验通过且评分有效的任务；误差线为患者簇 95% 重采样区间（1,000 次，种子 42），n 与 P 分别为评分题数和患者数。

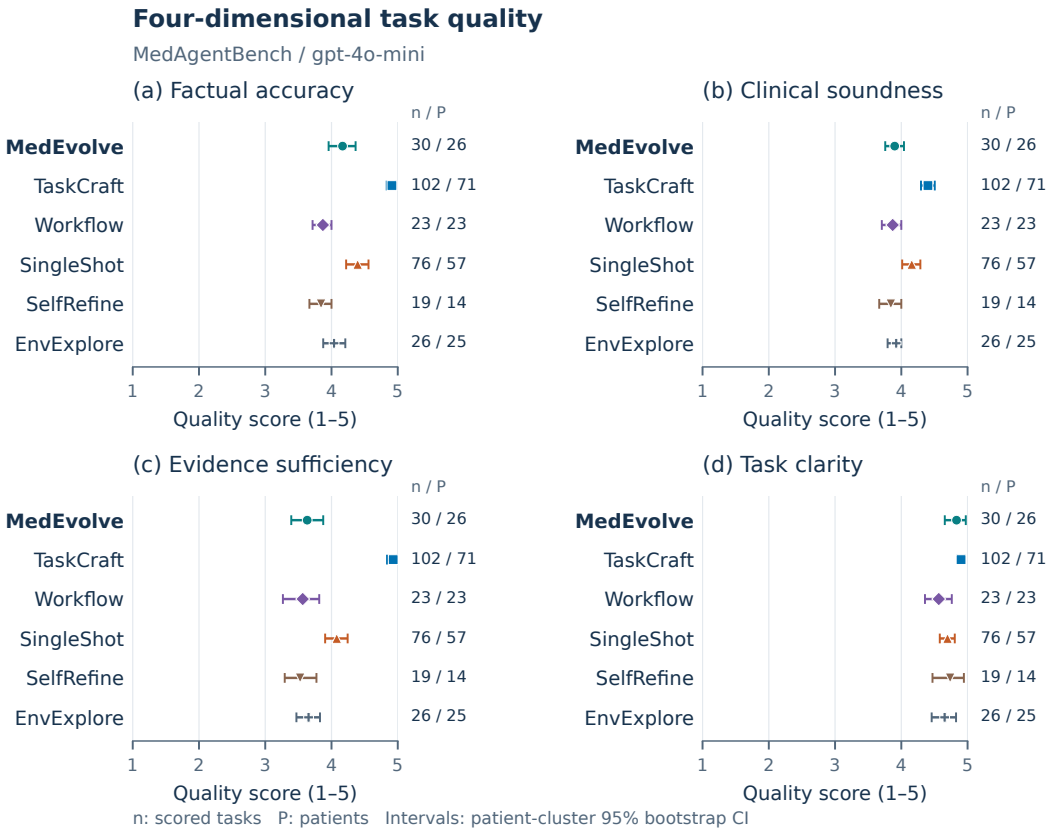


图 8. MedAgentBench、gpt-4o-mini 条件的四维质量。仅统计核验通过且评分有效的任务；误差线为患者簇 95% 重采样区间（1,000 次，种子 42），n 与 P 分别为评分题数和患者数。

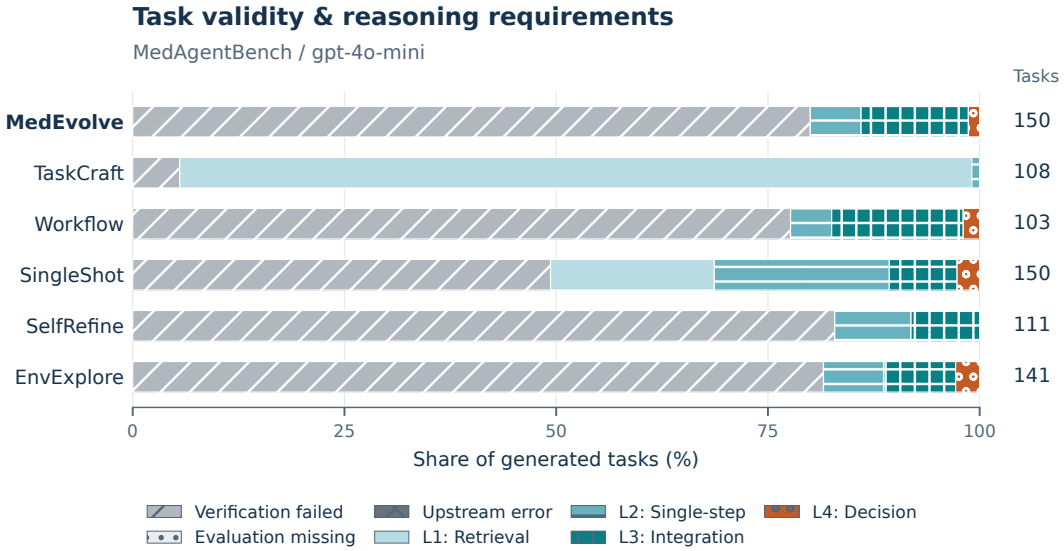


图 9. MedAgentBench、gpt-4o-mini 条件的核验状态与推理层级，口径与图 1 相同。

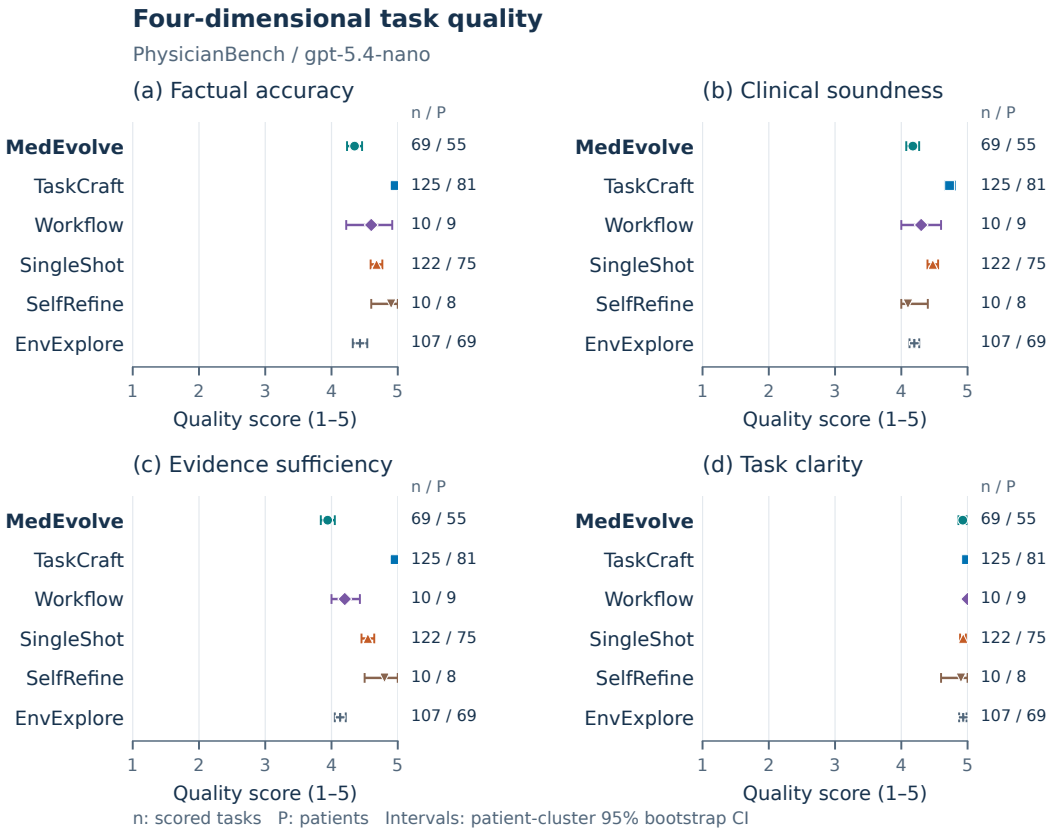


图 10. PhysicianBench、gpt-5.4-nano 条件的四维质量。仅统计核验通过且评分有效的任务；误差线为患者簇 95% 重采样区间（1,000 次，种子 42），n 与 P 分别为评分题数和患者数。

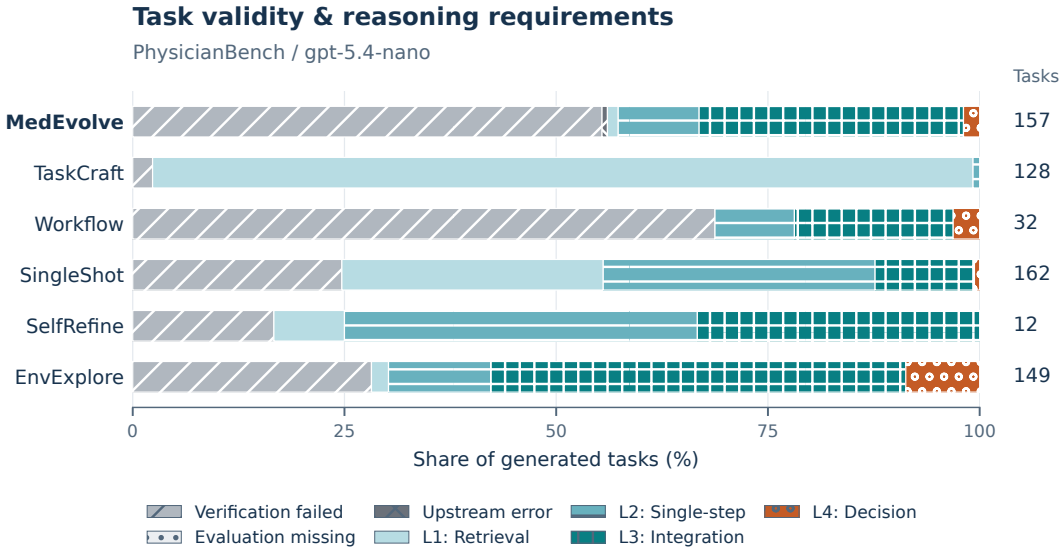


图 11. PhysicianBench、gpt-5.4-nano 条件的核验状态与推理层级，口径与图 1 相同。

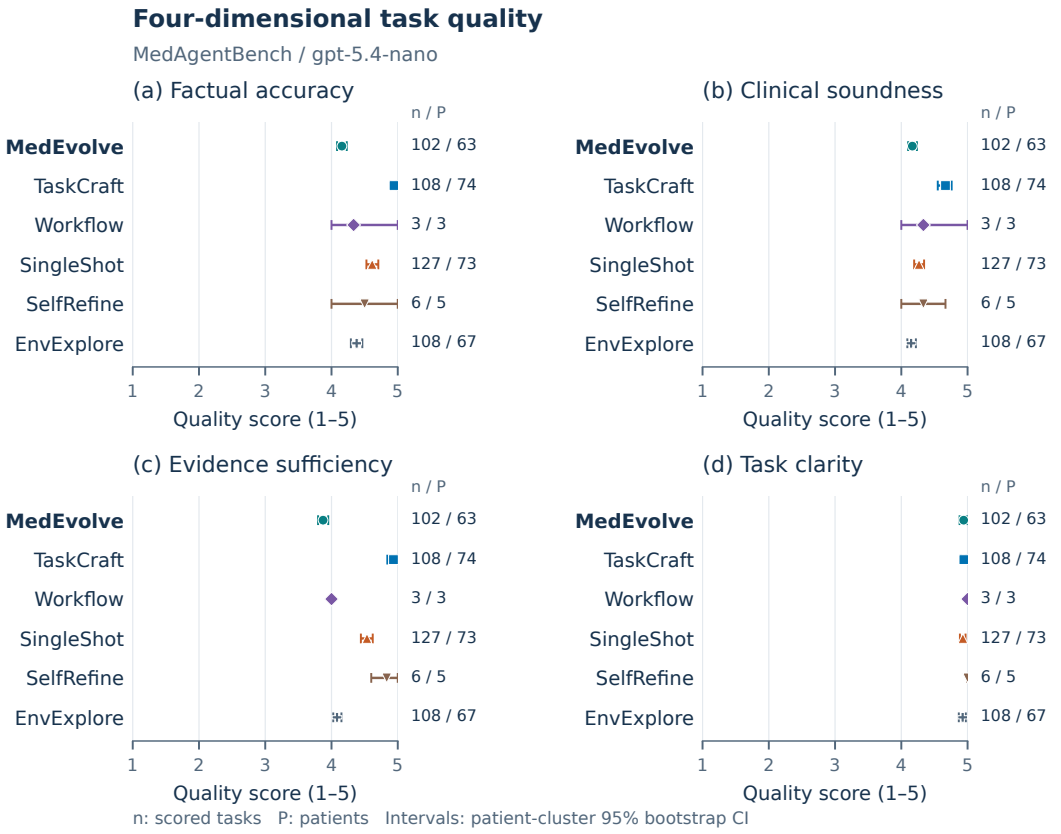


图 12. MedAgentBench、gpt-5.4-nano 条件的四维质量。仅统计核验通过且评分有效的任务；误差线为患者簇 95% 重采样区间（1,000 次，种子 42），n 与 P 分别为评分题数和患者数。

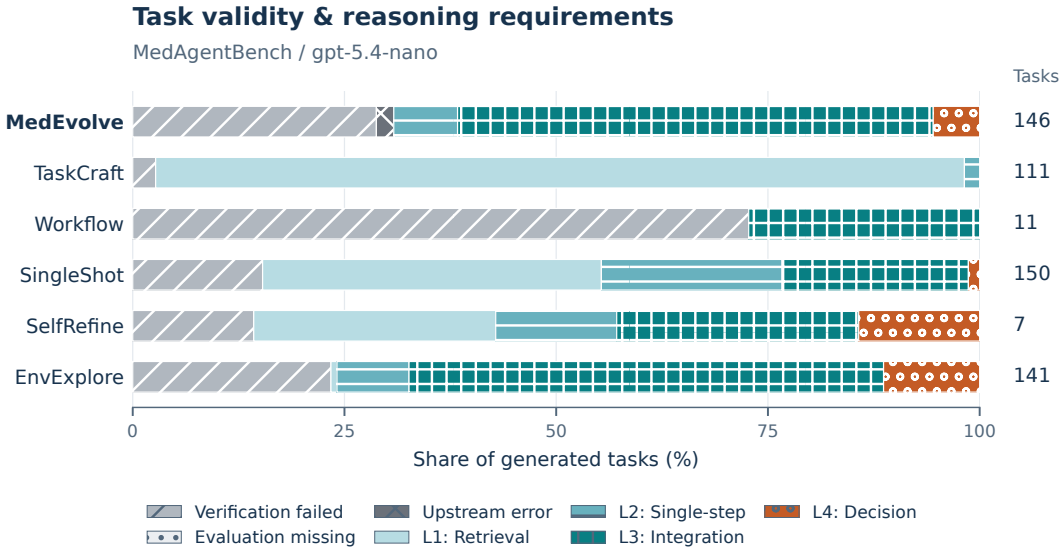


图 13. MedAgentBench、gpt-5.4-nano 条件的核验状态与推理层级，口径与图 1 相同。

表 8. 推理要求与证据结构。核验通过率以已有核验结果为分母；高阶与证据指标统计核验通过且具有难度评分的任务。方括号为患者簇 95% 区间（1,000 次重采样，种子 42），高阶区间对应分子题数。跨度括号内为时间可解析题数。

方法	通过率% [95% 区间]	高阶题数 / 评分题数 [95% 区间]	高阶占比	平均证据数	平均资源类型数	跨度中位数（天）
PhysicianBench / gpt-4o-mini						
MedEvolve	19.9[13.2,27.2]	16/32 [9,24]	50.0%	2.41	1.28	0.36 (32)
TaskCraft	88.2[82.6,94.0]	0/105 [0,0]	0.0%	1.24	1.04	0.00 (105)
Workflow	18.0[12.1,24.8]	15/25 [8,22]	60.0%	2.88	1.36	6.00 (25)
SingleShot	53.1[43.8,62.3]	10/86 [4,16]	11.6%	2.13	1.08	0.00 (86)
SelfRefine	25.7[16.7,35.7]	12/26 [6,19]	46.2%	2.62	1.19	2.00 (26)
EnvExplore	16.9[11.2,22.5]	14/27 [7,22]	51.9%	2.59	1.22	1.00 (27)
MedAgentBench / gpt-4o-mini						
MedEvolve	20.0[13.3,26.7]	21/30 [13,29]	70.0%	2.47	1.23	0.62 (30)
TaskCraft	94.4[89.0,98.9]	0/102 [0,0]	0.0%	1.27	1.01	0.00 (102)
Workflow	22.3[15.1,29.5]	18/23 [11,26]	78.3%	3.39	1.09	3.00 (23)
SingleShot	50.7[42.7,58.0]	16/76 [9,23]	21.1%	2.53	1.04	0.43 (76)
SelfRefine	17.1[9.2,25.9]	9/19 [3,16]	47.4%	2.89	1.05	1.68 (19)
EnvExplore	18.4[12.6,25.0]	16/26 [9,24]	61.5%	2.54	1.15	2.00 (26)
PhysicianBench / gpt-5.4-nano						
MedEvolve	44.6[37.1,52.6]	52/69 [41,65]	75.4%	5.20	1.75	18.87 (69)
TaskCraft	97.7[94.9,100.0]	0/125 [0,0]	0.0%	1.22	1.03	0.00 (125)
Workflow	31.2[14.3,50.0]	7/10 [3,12]	70.0%	6.00	1.90	1.17 (10)
SingleShot	75.3[68.5,81.5]	20/122 [12,29]	16.4%	3.89	1.27	0.64 (122)
SelfRefine	83.3[61.5,100.0]	4/10 [1,8]	40.0%	2.50	1.10	20.00 (10)
EnvExplore	71.8[64.1,78.8]	86/107 [72,100]	80.4%	6.21	1.65	22.75 (107)
MedAgentBench / gpt-5.4-nano						
MedEvolve	71.2[61.6,79.9]	90/101 [77,104]	89.1%	6.76	1.32	8.39 (101)
TaskCraft	97.3[94.1,100.0]	0/108 [0,0]	0.0%	1.18	1.01	0.00 (108)
Workflow	27.3[0.0,53.9]	3/3 [0,7]	100.0%	8.67	2.00	38.04 (3)
SingleShot	84.7[78.7,90.0]	35/127 [26,44]	27.6%	5.04	1.09	0.90 (127)
SelfRefine	85.7[50.0,100.0]	3/6 [0,8]	50.0%	7.67	1.00	1.50 (6)
EnvExplore	76.6[69.9,82.9]	95/108 [83,107]	88.0%	6.51	1.56	2.90 (108)