面向纵向电子健康记录的 Agent 任务生成：证据锚定与策略进化

摘要

从纵向电子健康记录（EHR）中为医疗 Agent 生成高质量任务面临挑战：不同患者记录能够支持的临床关系各不相同，而可用工具又限制了证据的检索方式。本文提出 MedEvolve，从任务证据锚定与策略进化两个互补层面改进医疗任务生成。在任务构建层面，双探索将反复出现的临床时序模式与工具访问约束提炼为可复用的指导。在策略层面，反馈驱动的进化进一步将核验与独立解题结果转化为跨患者的任务构建规则和任务方向偏好，而非仅修复单个问题。在两个基准上，MedEvolve 的核验通过高阶任务产出率均高于基线方法。加入其合成任务后，ACE 与 Reflexion 在官方测试任务上的成功率分别提高 6 和 2 个百分点。

1 引言

纵向电子病历记录患者多次就诊中的诊断、检查与治疗，是构建医疗 Agent 任务的主要数据来源。MedAgentBench 与 PhysicianBench 在此类环境中评测 LLM Agent (Jiang et al., 2025; Liu et al., 2026)，但任务通常依赖临床专家设计与审核，难以大规模扩展。自动生成方法中，TaskCraft 从文档内容构建原子任务，经核验后进行深度与宽度扩展，并利用核验通过率优化少样本提示配置 (Shi et al., 2026)；CuES 与 AgentEvolver 从环境交互轨迹中合成任务，并通过执行检查验证可行性 (Mai et al., 2025; Zhai et al., 2025)。上述工作从文档内容或环境交互中构造可核验任务。本文进一步关注多患者纵向病历中的临床事件、时间关系及证据模式，并利用任务核验与独立解题反馈，跨患者更新生成指导和任务方向权重。

纵向病历任务生成面临两个困难。首先，任务是否成立同时取决于病例内容与工具能力：当前患者轨迹无法揭示跨患者反复出现的临床关系及其证据分布，完整轨迹也可能超出输入预算；所需证据能否通过工具检索，还需实际交互核查。其次，不同病例所支持的任务类型与推理要求不同，生成指导需要吸收证据核验和独立解题中暴露的任务构造问题。

本文提出 MedEvolve，通过数据与环境双探索提炼可复用指导，再利用核验与独立解题反馈，跨患者更新生成策略，整个过程不更新模型参数。主要贡献包括：（1）结合临床事件模式与工具访问约束，支持有证据依据的任务生成；（2）利用评价反馈修订自然语言生成指导和任务方向权重；（3）在两个 EHR 环境中评价有效高阶任务产出，并检验合成任务的下游经验学习价值。

2 方法

2.1 问题设置

给定医疗环境 $\mathcal{E}$ 和纵向患者轨迹集合 $\mathcal{D} = \{X_p\}$，目标是为每条轨迹 X_p 构造医疗 Agent 任务。每个任务由指令 q、候选参考答案 a 和来源证据 e 组成。生成过程由策略 $\theta_r = (g_r, w_r)$ 控制：g_r 是自然语言生成指导，w_r 是任务类型和难度方向的采样权重，r 为进化轮次。MedEvolve 先通过探索得到数据指导 K_D 与环境指导 K_E，再利用评价反馈更新 θ_r。整体流程见图 1。

2.2 数据探索与环境探索

单个患者的轨迹只说明该病例包含哪些记录，难以判断这些记录在整个数据源中属于何种模式，也无法在每次生成时重复读取大量患者。因此，我们在生成之前先进行数据探索，把跨患者的观察整理为可复用的指导。

数据探索针对纵向患者轨迹。探索 Agent 读取多位患者的记录，分析数据的组织方式、时间变化、临床事件之间的关联和证据分布，归纳出不同类型任务所需的信息模式，形成数据指导 K_D。K_D 只描述可复用的模式，不包含特定患者的临床事实。

环境探索针对环境接口。探索 Agent 实际调用只读查询工具，记录访问方式、返回结构和交互约束，形成环境指导 K_E，用于判断一个问题所需的证据能否通过工具获取。

两类探索在初始化阶段完成，之后的所有轮次中保持不变。

2.3 任务生成与评价

对于患者 X_p，生成器以 K_D、K_E 和当前策略 θ_r 为条件，按指定的任务类型和难度方向生成 (q, a, e)，其中关键事实附带对原始记录的引用。

候选任务随后依次经过核验、评分和独立解题。核验重新读取原始记录，检查证据声明对参考答案的支持；通过核验的任务再接受任务质量和推理深度的评价，并由固定的 Agent 在环境中独立作答。解题 Agent 无法获得参考答案和证据声明。

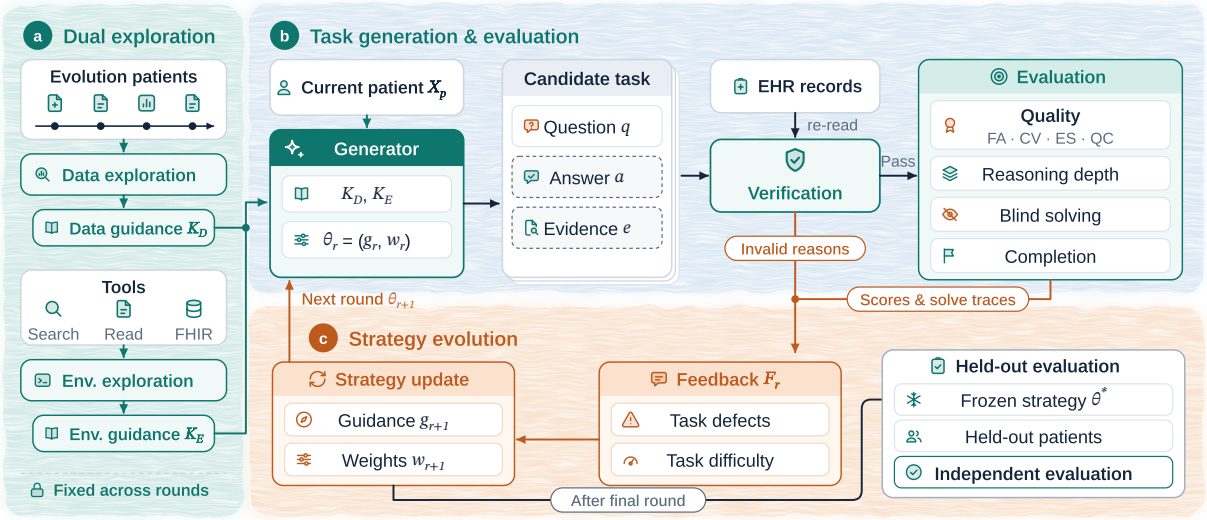


图 1. MedEvolve 方法概览。(a) 数据与环境双探索形成固定复用的指导 K_D 与 K_E。(b) 生成器结合患者轨迹、探索指导和当前策略构建任务，经原始记录核验后开展质量、推理深度、独立解题与完成评价；解题 Agent 不接收参考答案和证据声明。(c) 评价反馈修订生成指导与方向权重；进化结束后冻结策略，在留出患者上评测。

2.4 反馈驱动的策略更新

每轮结束后，系统汇总该轮任务的核验缺陷、质量与推理评分以及解题轨迹，归因得到反馈 F_r。归因需要区分任务本身的缺陷（如事实错误、证据不足、题意歧义）、任务带来的真实推理难度，以及模型、工具或环境故障，以避免将执行异常当作任务难度。策略按下式更新：

$$\theta_{r+1} = \mathcal{U}(\theta_r, F_r), \tag{1}$$

其中 $\mathcal{U}$ 由 LLM 实现。更新作用于两个部分：一是把具有普遍性的构造经验写入 g_{r+1}，调整临床信息的选择、证据的组织和任务设计；二是根据各方向的质量与难度表现调整 w_{r+1}，改变后续任务的方向分布。

不同轮次使用不同的患者批次生成任务。完成预定轮次后冻结策略，并在独立的患者集上评测。

3 实验

3.1 评测条件与指标

环境与比较条件。实验覆盖 PhysicianBench 与 MedAgentBench，分别使用 108 与 100 位具有临床记录的患者，其中 81 与 75 位用于留出评测，其余用于策略进化，两组患者互不重叠。各方法共享留出患者与生成模型 GPT-5.4-nano，每位患者最多生成两道只读任务，固定请求题数分别为 162 与 150。患者划分与信息访问规则见附录 C.1。

评价指标。任务先对照原始记录核验，再由 GPT-4o-mini 与 GPT-5.4-nano 独立评价最小充分推理需求，聚合为 1–4 级。通过核验且层级不低于 3 的任务计为高阶题。主要指标为高阶题数及其占固定请求题数的比例，即有效高阶产出率，生成失败和无效任务造成的损失均计入；全部通过核验且具有难度评分的任务的平均层级作为辅助指标。评分与聚合细则见附录 B。

3.2 实验一：有效高阶题生成

我们比较不同生成方式能否在相同患者和题数上限下产出更多有效高阶任务。SingleShot 单次生成任务，Workflow 采用定位、生成与筛选流程，SelfRefine (Madaan et al., 2023) 通过自反馈修订候选，TaskCraft 通过深度与宽度扩展提高复杂度。EnvExplore 使用环境探索指导与固定初始策略；MedEvolve 则结合数据与环境双探索，使用两轮反馈更新后的完整策略。各方法的调用与计算投入不同，比较限定于共同患者和题数上限；具体流程与预算见附录 C.2。

表 1 显示，MedEvolve 在两个环境中的有效高阶产出率均最高，但相对最接近的 EnvExplore，其优势随环境变化：MedAgentBench 上多产出 13 道高阶题，产出率高出 8.6 个百分点；PhysicianBench 上仅多出 2 道，高出 1.2 个百分点。因此，结果支持完整框架在本次评测中的产出优势，但 PhysicianBench 上的差距较小。

核验通过率与高阶产出反映不同的任务特性。TaskCraft 的有效题平均层级接近 1，未产出高阶题；MedEvolve 的核验通过率低于部分基线，却保留了最多的有效高阶题（附录 D），说明

方法	PhysicianBench		MedAgentBench	
	高阶题数（产出率）	平均层级	高阶题数（产出率）	平均层级
MedEvolve	**23（14.2%）**	2.27	**77（51.3%）**	**2.73**
EnvExplore	21（13.0%）	2.25	64（42.7%）	2.56
TaskCraft	0（0.0%）	1.01	0（0.0%）	1.00
Workflow	3（1.9%）	**2.30**	2（1.3%）	2.67
SingleShot	3（1.9%）	1.20	11（7.3%）	1.44
SelfRefine	4（2.5%）	2.20	2（1.3%）	2.00

表 1. 有效高阶任务产出比较（生成模型：GPT-5.4-nano）。高阶题通过证据核验且聚合层级不低于 3；括号内为产出率，以固定请求题数为分母（PhysicianBench：162；MedAgentBench：150）。平均层级基于全部通过核验且具有难度评分的任务。粗体表示各列最高值。

仅考察核验通过率不足以评价生成任务的推理要求。平均层级也需结合样本量解读：PhysicianBench 上 Workflow 的均值略高于 MedEvolve（2.30 对 2.27），但仅基于 10 道通过核验的任务。

3.3 实验二：合成任务补充官方任务训练

我们进一步检验合成任务能否补充官方任务，改善经验学习后的测试表现。在 PhysicianBench 中，ACE (Zhang et al., 2026)、Reflexion (Shinn et al., 2023) 与 OpenClaw (OpenClaw contributors, 2026) 分别从两种训练设置中积累经验：“官方 20”使用 20 道官方任务；“官方＋合成 40”在同一批官方任务上增加 20 道通过核验的 MedEvolve 任务。两组使用同一执行模型 Qwen3.8-27B，固定模型参数，并在训练后冻结经验，在共同的 50 道官方测试任务上评测。参考答案仅用于评分；框架机制与复现设置见附录 C.3。

表 2. 官方任务训练加入合成任务前后的题目通过率。通过率以全部 50 道计划测试题为分母，表示严格的整题成功。ACE 的官方组与混合组分别有 48 与 50 题完成评分，其余框架均覆盖 50 题。

框架	官方 20	官方＋合成 40	差值
ACE	4.0%（2/50）	10.0%（5/50）	+6.0 pp
Reflexion	12.0%（6/50）	14.0%（7/50）	+2.0 pp
OpenClaw	24.0%（12/50）	20.0%（10/50）	−4.0 pp

补充合成任务后，ACE 与 Reflexion 的通过率分别提高 6.0 与 2.0 个百分点，OpenClaw 则下降 4.0 个百分点（表 2）。这说明合成任务在部分经验学习框架中具有潜在价值，但本次评测未呈现一致收益。不同框架采用不同的经验载体与更新机制，可能影响合成任务的利用效果，当前比较尚不能确定收益差异的原因。

4 结论

本文提出 MedEvolve，将数据探索与环境探索结合，使医疗 Agent 任务生成同时受到患者纵向病历内容和工具证据获取能力的约束，并利用核验与独立解题反馈跨患者更新生成指导和任务方向权重，整个过程不更新模型参数。

在 PhysicianBench 与 MedAgentBench 上，MedEvolve 在六种对比方法中均取得最高的有效高阶任务产出，分别产出 23 道与 77 道通过核验的高阶题。下游经验学习实验进一步呈现了合成任务在部分框架中的潜在价值：加入合成任务后，ACE 与 Reflexion 的官方测试通过率提高，OpenClaw 则下降，体现出框架间的收益差异。这些发现支持将双探索任务生成作为构建医疗 Agent 高阶任务的一种方法，并为研究合成任务与经验学习机制的适配关系提供了实证依据。

局限性（Limitations）

下游经验学习实验比较了 20 道官方任务与加入 20 道合成任务后的训练设置，任务数量和组成同时发生变化。等量官方任务及其他生成方法所产任务的对照，有助于进一步区分训练规模与合成任务特性的影响。当前下游结果来自 PhysicianBench 上的单种子、50 道测试题，收益的稳定性及其在其他环境中的表现仍需更多评测。

MedEvolve 的生成指导从特定环境的患者记录与工具接口中提炼，当前独立患者评测考察的是同一环境内的策略迁移。当医疗机构、记录结构或证据检索工具发生变化时，已有指导的适用性及所需调整尚未得到系统评价。

References

Yixing Jiang, Kameron C. Black, Gloria Geng, Danny Park, James Zou, Andrew Y. Ng, and Jonathan H. Chen. 2025. MedAgentBench: A virtual EHR environment to benchmark medical LLM agents. *NEJM AI*, 2(9):AIdbp2500144.

Timothy Kassis, Vinayak Agarwal, Yuhuan He, Darshil Patel, and Aubrey M. Brueckner. 2026. Scientific agent skills: A library of procedural knowledge for research agents. *arXiv preprint arXiv:2609.00065*.

Ruoqi Liu, Imran Q. Mohiuddin, Austin J. Schoeffler, Kavita Renduchintala, Ashwin Nayak, Prasantha L. Vemu, Shivam C. Vedak, Kameron C. Black, John L. Havlik, Isaac Ogunmola, Stephen P. Ma, Roopa Dhatt, and Jonathan H. Chen. 2026. PhysicianBench: Evaluating LLM agents in real-world EHR environments. *arXiv preprint arXiv:2605.02240*.

Aman Madaan, Niket Tandon, Prakhar Gupta, Skyler Hallinan, Luyu Gao, Sarah Wiegreffe, Uri Alon, Nouha Dziri, Shrimai Prabhumoye, Yiming Yang, Shashank Gupta, Bodhisattwa Prasad Majumder, Katherine Hermann, Sean Welleck, Amir Yazdanbakhsh, and Peter Clark. 2023. Self-Refine: Iterative refinement with self-feedback. In *Advances in Neural Information Processing Systems*, volume 36, pages 46534–46594. Curran Associates, Inc.

Shinji Mai, Yunpeng Zhai, Ziqian Chen, Cheng Chen, Anni Zou, Shuchang Tao, Zhaoyang Liu, and Bolin Ding. 2025. CuES: A curiosity-driven and environment-grounded synthesis framework for agentic RL. *arXiv preprint arXiv:2512.01311*.

OpenClaw contributors. 2026. OpenClaw. Open-source software. Version 2026.9.2; commit 3928bad9badfcb6c7d140530435e806fb8092190.

Dingfeng Shi, Jingyi Cao, Qianben Chen, Weichen Sun, Weizhen Li, Hongxuan Lu, Fangchen Dong, Tianrui Qin, King Zhu, Minghao Liu, Yuchen Eleanor Jiang, Jian Yang, Ge Zhang, Jiaheng Liu, Changwang Zhang, Jun Wang, and Wangchunshu Zhou. 2026. TaskCraft: Automated generation of agentic tasks. In *The Fourteenth International Conference on Learning Representations*.

Noah Shinn, Federico Cassano, Ashwin Gopinath, Karthik Narasimhan, and Shunyu Yao. 2023. Reflexion: language agents with verbal reinforcement learning. In *Advances in Neural Information Processing Systems*, volume 36, pages 8634–8652. Curran Associates, Inc.

Yunpeng Zhai, Shuchang Tao, Cheng Chen, Anni Zou, Ziqian Chen, Qingxu Fu, Shinji Mai, Li Yu, Jiaji Deng, Zouying Cao, Zhaoyang Liu, Bolin Ding, and Jingren Zhou. 2025. AgentEvolver: Towards efficient self-evolving agent system. *arXiv preprint arXiv:2511.10395*.

Qizheng Zhang, Changran Hu, Shubhangi Upasani, Boyuan Ma, Fenglu Hong, Vamsidhar Kamanuru, Jay Rainton, Chen Wu, Mengmeng Ji, Hanchen Li, Urmish Thakker, James Zou, and Kunle Olukotun. 2026. Agentic context engineering: Evolving contexts for self-improving language models. In *The Fourteenth International Conference on Learning Representations*.

A 核心提示词与真实案例

以下为当前公开实现中主方法的关键提示词原文节选。探索输出可复用指导；生成器输入患者轨迹、探索指导、当前策略及两个采样方向，输出问题、候选答案与逐来源证据；任务评价与独立解题结果用于反馈分析，更新生成指导和方向权重。

A.1 数据探索

```
你是医疗任务数据探索 Agent。
压缩摘要不是原始证据，标记为截断时只覆盖部分记录，
不能据摘要遗漏判断事实不存在。
归纳数据的组织方式、时间变化、病程关联、
证据引用方式和可支持的出题机会。
输出 DataExploration: guidance
是不绑定具体患者的抽象数据指导。
不要在指导中复述患者 ID、具体患者事实或其来源
ID；不要补充缓存未提供的事实。
```

A.2 环境探索

```
你是医疗任务环境探索 Agent。
通过本次独立环境提供的原生工具，了解查询工具名称、
参数、返回结构及操作约束。
仅访问工具开放的患者范围；只执行查询，
不尝试写入或模拟提交。
交付指导前必须实际调用本次环境工具，
不能仅凭函数清单认定能力已验证。
指导中明确区分已验证能力、调用失败与未验证能力；
不要将具体患者观察或患者 ID 沉淀为公共指导。
不要把工具或环境故障归纳成任务难度，
也不要声称未验证的能力已可用。
```

A.3 任务生成

```
你是医疗任务生成角色。
输入包含一个患者的缓存轨迹、固定的数据探索指导、
固定的环境探索指导、当前策略，
以及按位置排列的两个生成方向。
按照这两个位置的题型和难度分别尝试生成一道任务。
一次输出 TaskBatch, questions 最多两题；
证据不足时允许少出题或输出空列表，不能补造。
没有查询工具。仅使用传入轨迹中的事实和来源 ID，
结合指导与策略确定题目。
先从 trajectory.sources 的原始记录选择事实，
再围绕这些事实构造题目、答案和证据。
evidence 每条 statement 只陈述该 source_id
实际支持的事实；跨记录结论分别引用各条依据。
需要比较两条记录才能成立的关系放在
reference_answer 中，evidence
分别陈述每条记录的原始事实。
不能把轨迹未出现某项事实推断为该事实不存在、
检查未做或结果正常；
证据不足以支持任务时跳过该题位。
真实后续治疗不是临床决策题的唯一答案，
允许有依据的合理等价方案。
```

A.4 反馈分析与策略更新

反馈分析。

```
你是医疗任务出题策略的反馈分析角色。
区分质量问题、临床难度、证据不足、题意歧义及工具、
环境、模型运行故障。
工具或环境故障、模型故障、
预算耗尽不能解释为临床难度提升；
没有可靠完成评价时，明确结论受限，
不能推断任务更难或解题失败。
建议针对选题、证据组织、参考答案表述及生成方向，
说明生成过程可以如何调整。
```

策略更新。

```
你是医疗任务出题策略更新角色。
只根据当前 Strategy 与 Feedback，一次输出新的
Strategy。
更新 generation_guidance 和 allocation；
初始数据探索指导与环境探索指导保持固定，
由实验入口管理。
将有证据支持的经验和新出题模式沉淀为自然语言指」
导，不绑定具体患者。
经验保留其适用的证据与任务条件；
个别题目的证据条数、时间点或回答格式，
不自动成为所有题型的固定要求。
将反馈转化为可复用的选题与组织方式，
而不是累积每个病例的作答要求；
材料不支持某种模式时，
可选择同题型下其他合适的问题。
配比只安排每次两个生成位置，不改变生成数量；
不限制自然语言模式如何变化。
反馈证据不足时保留相应策略，不通过更复杂的题意、
缺失数据或工具故障制造难度。
```

五类方向为诊断与解释、检查与风险分层、治疗规划、药物处方和治疗重规划。每患者按权重抽取两个方向；探索指导固定，反馈只更新生成指导和方向列表。两轮更新后冻结完整策略，用于留出患者评测。

A.5 证据核验与指导修订案例

以下案例来自 PhysicianBench 一次进化运行的第一轮记录。

生成任务。“考虑患者在 2024 年 1 月 5 日和 2024 年 1 月 21 日的实验室结果，评估其血糖和血脂水平的变化，以及对其健康管理的潜在影响。请使用相关的观察和诊断资料支持你的评估。”候选参考答案包含：“在 1 月 21 日的记录中，未见到进一步的血糖异常记录，说明在一定程度上患者的血糖得到控制。”

证据核验。任务将 Condition/2402 声明为“高血糖”，原始记录却为高脂血症（ICD-10-CM E78.5），核验未通过。轮末反馈另指出：缺失血糖复查结果不能支持“得到控制”。

指导修订。更新后的生成指导写入：“纵向变化任务先确认可比数据：同一指标、同一单位、相近检测条件、明确基线与随访时间；缺失随访结果时不得推断‘得到控制’‘病情改善’或‘恶化’。”检查与风险分层方向同步限定为基线与随访数据可比时进行整合，证据缺失时限定结论；该轮各方向权重仍为 1。

来源。outputs/physicianbench-evolution-comparison-20261005-234810/run/rounds/0001/ 下的任务、核验、反馈及更新策略记录；任务编号后缀为 0001:1:1。

B 证据核验与推理评价

B.1 证据核验提示词

核验先逐条重读引用的原始记录，再检查题目及候选答案整体是否成立。以下为当前核验提示词的关键节选。

```
只判断当前一条证据声明是否受当前这条原始记录支」
持。
resource 是从环境按 evidence.source_id
直接读取的原始记录。
逐项核对 statement 中的药物名称、剂量、检验值、
时间等事实。
只有这条记录支持全部声明时 valid=true；
矛盾或没有记载时 valid=false。
不得用其他记录或临床常识替代当前引用。reason
写明 source_id 和支持或冲突的具体事实。

核验题目和参考答案是否受 evidence_records
中的原始数据支持。
这些记录已从环境读取，证据声明已逐条核验。
不要推定记录未提供的患者事实。
决策点后的资料可支持参考答案，
但后续真实治疗并非临床决策题唯一正确方案。
题目含糊、证据不足或参考答案不正确时返回
valid=false，并解释依据。
```

B.2 推理深度提示词

实验一难度复评使用下列冻结提示词节选。输入包括题干、候选参考答案、证据声明和辅助复杂度信息；评分依据正确满足核心要求所需的最简充分解题路径。

```
评估医疗任务正确完成所必需的推理深度，1-4 分。
先检查题干、证据和候选答案，
找出正确满足核心要求的最简充分解题路径，
再按这条路径评分。不能只根据题干宣称需要
“综合分析”“制定方案”评分；
候选参考答案不自动正确，也不代表唯一解题路径。
1分=事实检索：读取、匹配、计数、
汇总记录或复述已明确记载的诊断即可回答。
多条重复诊断或记录不自动提高层级。
2分=简单判断：
事实结合一条临床规则即可得出核心结论，
包括异常判断、药物与适应证的简单匹配、
通用检查或管理建议。
并列完成多个独立简单判断不自动成为3分。
3分=必要整合：
核心结论必须依赖多个独立事实之间的关系，
完成时间比较、竞争解释比较或条件推导。指出至少」
两个不可替代的事实以及它们如何共同改变结论；
若删去其中一个关键事实，结论应改变或无法成立。
证据多、跨度长、约束多、答案长本身不加分。
```

表 3. 临床患者池与两轮进化划分。

环境	总数	进化集	评测集	两轮人数
PhysicianBench	108	27	81	13 / 14
MedAgentBench	100	25	75	12 / 13

4分=决策权衡：
需要在多个合理备选方案之间进行患者特异的选择；
明确至少两个备选方案、相互冲突的收益风险或限制，
以及患者证据为何决定取舍。仅提出检查清单、
通用治疗建议、严重疾病需要重视或明显应重估管理，
不足以获得4分。
检查捷径：题干是否已给出核心结论；
诊断标签是否直接包含答案；
是否读取单条记录即可回答；是否只需套用通用建议。
按仍需完成的实质推理评分。
reason依次写明：最简充分解题路径；必要事实及关系；
捷径检查；为什么满足本层级及为什么不满足更高层级。
对于4分必须写出方案、取舍和决定性患者证据。
无法从输入确认的病历事实应标明，不得补造。

GPT-4o-mini 与 GPT-5.4-nano 独立评分；两份有效评分取中位数并向下取整，缺任一份则不形成聚合层级。通过核验且聚合层级不低于 3 的任务计为高阶题。

高阶产出率以固定请求题数为分母（PhysicianBench：162；MedAgentBench：150），生成不足与无效任务均不从分母剔除。平均层级仅统计通过核验且具有完整难度评分的任务。

C 实验与复现设置

C.1 患者划分与信息访问

患者池仅纳入具有临床记录的患者，MedAgentBench 中仅含人口学记录的患者不进入生成队列。按种子 42 冻结名单，既有探索暴露患者保留在进化集；进化与留出评测患者互不重叠。模型输入按预算裁剪，核验读取原始来源。生成与解题任务为只读；题干中的时间限定不代表工具隐藏后续记录。

C.2 模型与基线适配

实验一生成与独立解题模型为 GPT-5.4-nano，核验与完成裁判为 GPT-5.4-nano，难度裁判为 GPT-4o-mini 与 GPT-5.4-nano。六种方法共享留出患者、每患者最多两题和公共评价。

TaskCraft 将患者记录与只读 FHIR 工具适配到结论抽取、原子任务生成、核验及深度 / 宽度扩展；两个扩展分支独立出发并共享生成预算。Workflow 执行定位、生成与筛选；SingleShot 单次生成；SelfRefine 最多三次自评、两次修订，通过后提前结束；EnvExplore 使用环境指导和固定初始策略。MedEvolve 使用双探索及两轮更新后的完整策略。各方法内部调用量不同，此比较不控制为相同计算投入。

表 4. 实验一各方法的任务产出（生成模型：GPT-5.4-nano）。核验为核验通过题数。

	PhysicianBench		MedAgentBench	
方法	生成	核验	生成	核验
MedEvolve	157	70	146	104
EnvExplore	141	93	141	108
TaskCraft	128	125	111	108
Workflow	32	10	11	3
SingleShot	162	122	150	127
SelfRefine	12	10	7	6

C.3 下游经验学习与官方评测

执行模型为 Qwen3.8-27B（UD-Q4_K_M 量化），关闭思考，每题模型调用预算为 100，种子为 42。两组从相同初始状态出发，共用 20 道官方训练题；混合组另加入通过核验的 MedEvolve 合成题，GPT-4o-mini 与 GPT-5.4-nano 各生成 10 道。训练后冻结经验，在共同的 50 道官方测试题上使用 PhysicianBench 原生检查点评分；参考答案仅用于评分。

ACE 更新策略手册，Reflexion 保存反思与可迁移经验，OpenClaw 通过原生 Skill Workshop 更新技能。Reflexion 每题读取最多三条相关经验，不保存患者标识、个体临床值或逐题答案。测试期间经验不更新，也不依据评分进行反思或重试。

测试通过率以全部 50 道计划题为分母。ACE 官方组与混合组分别完成 48 与 50 题评分，Reflexion 与 OpenClaw 各组均覆盖 50 题。

D 补充产出数据

写作辅助工具 中文稿的结构组织、方法描述核对与证据状态检查使用 Scientific Agent Skills 的 scientific-writing 技能 (Kassis et al., 2026) 辅助。文献与科学结论的最终核验由作者负责。