MedEvolve：基于双探索的纵向医疗任务生成与策略自进化

摘要

在患者纵向病历中自动构建医疗 Agent 任务，既需要识别跨就诊事件中的临床时序逻辑，也需要确保该逻辑在受限的工具环境中具备闭环可检索的证据支撑。本文提出 MedEvolve，通过数据探索提炼临床事件模式，通过环境探索核查工具检索能力，两类指导共同约束生成器围绕真实病程组织问题、参考答案与来源证据。在此基础上，系统结合原始证据核验与独立解题反馈进行错误归因，迭代修订生成规则并动态调整采样配比，实现任务质量与推理难度的协同演进。实验覆盖 PhysicianBench 与 MedAgentBench，结果表明 MedEvolve 显著改善了有效任务产出并提升了高阶推理要求；同时，由该方法合成的任务能够有效沉淀为可迁移经验，在官方基准上实质性增强了医疗 Agent 的下游决策表现。

1 引言与相关工作

1.1 纵向病历中的任务生成

MedAgentBench 与 PhysicianBench 将医疗 Agent 的评测置于可交互的电子病历环境中，要求 Agent 检索患者记录、整合信息并完成临床相关任务（Jiang et al., 2025；Liu et al., 2026）。这类任务的构建需要从病历中选择问题，并确定答案所依赖的记录。随着任务从单条事实查询扩展到多次就诊之间的信息整合，出题依据也从某个明确的数值或事件，转向患者病程中能够被记录共同支持的临床关系。

然而，不同患者的记录能够支持的关系并不相同。有些病例包含连续检查与多次治疗调整，适合围绕指标变化和治疗过程提问；另一些病例集中于单次就诊，或缺少关键时间点，只能支持较局部的判断。即使题型相同，问题所需的时间窗口、背景和证据也会随病例变化。因此，生成器不能仅根据预设题型寻找可填入的内容，还需要先判断当前病历有哪些特点、哪些关系值得提问，再选择相应的任务方向。

这种选择也不能仅由工具使用过程决定。通过查询获得的执行轨迹记录了 Agent 如何访问病历，患者的诊疗轨迹则记录了既有的治疗、检查与病情变化。一次成功检索可以说明相关信息能够获取，却不能说明这些信息已经构成一个有意义的临床问题。例如，围绕治疗调整前后的指标变化出题，除了找到用药和检查记录，还需要识别调整事件、区分比较时段，并判断检查是否能够支撑问题要求的分析。记录更多或调用更长，并不必然带来更深的临床推理。

在问题成立之后，参考答案仍需与提问范围相匹配。事实查询可以由记录中的数值或事件直接回答，治疗规划则可能存在多种合理方案，实际发生的后续处置不能自动成为唯一答案。若任务缺少必要证据，或将观察到的结果误作答案判据，解题失败就可能来自题目本身。生成策略因而需要同时利用任务核验与解题反馈，逐步调整适合不同病例的提问方式，而不是单纯增加问题的复杂度。

1.2 与已有工作的关系

TaskCraft 从工具返回内容中抽取候选答案及其关系，构造原子任务，再通过深度和宽度扩展增加检索依赖与组合结构（Shi et al., 2025）。这为围绕已知答案构建多步任务提供了途径，但纵向病历中的出题机会首先取决于病例本身：连续随访、治疗变化或局部就诊记录能够支持不同的问题。即使多个事实都可以查询，它们是否构成同一临床问题、适合哪种推理要求，仍需要结合当前病例判断。医疗任务生成因此需要在扩展问题结构之前，发现病例中可成立的提问方向。

CuES 和 AgentEvolver 从环境交互中提炼任务，分别通过执行指导或参考解检验任务可行性（Mai et al., 2025；Zhai et al., 2025）。这种思路能够发现环境支持的操作，但对于电子病历，相同的查询工具面对不同患者会返回内容和关联程度各异的记录。理解工具如何调用，并不足以确定某份病历适合问什么；成功重放查询也不能单独确认临床解释或答案的合理性。因此，环境探索还需要与患者数据的理解结合，将能够执行的检索过程转化为由当前病例支撑的问题。

MedEvolve 沿这一方向，将病例中的事件关系与工具的信息获取能力共同组织为出题指导，并通过跨患者的任务反馈修订生成策略。本文以任务生成侧的自进化为研究主体，在统一医疗环境中比较生成结果，再通过共同官方任务检验合成任务的下游价值。

1.3 本文贡献

本文提出 MedEvolve，以数据与环境双探索指导纵向医疗任务生成。数据探索归纳不同病例中可支持提问的事件关系和证据条件，环境探索识别相关信息的获取方式，两者共同帮助生

成器根据当前病例选择问题，而非将所有患者实例化为相同的提问模式。

在此基础上，MedEvolve 通过任务评价反馈推动生成策略自进化。每轮核验、质量评价和独立解题提供患者级反馈，随后被归纳为生成指导与方向权重的修订，使后续出题能够吸收已有病例中的经验，并适应观察到的证据缺陷和推理需求。研究在两个医疗环境中比较任务质量与有效产出，通过组件控制和固定患者上的策略比较考察自进化的作用，并以共同官方任务上的经验学习评价下游价值。

2 问题定义与方法

2.1 任务、指导与策略

设患者 p 的纵向轨迹为 X_p，医疗环境提供访问患者记录的工具集合。一个任务记为 $\tau = (p, q, a, E)$，其中 q 是问题，a 是候选参考答案，E 是由来源标识与事实声明构成的证据集合。解题 Agent 接收问题、患者标识和必要上下文，通过工具作答；参考答案与证据声明保留在评价侧。

双探索得到数据指导 K_D 与环境指导 K_E。第 r 轮策略为 $\theta_r = (g_r, W_r)$，其中 g_r 是可更新的自然语言生成指导，$W_r = \{(c_j, d_j, w_j)\}_j$ 是方向列表，分别包含临床题型 c_j、自然语言难度要求 d_j 和非负权重 w_j。临床题型限定为诊断与解释、检查与风险分层、治疗规划、药物处方和治疗重规划。题型描述问题内容，难度方向描述预期推理要求。

每个生成位置按归一化权重抽样：

$$\Pr(z = j \mid W_r) = \frac{w_j}{\sum_k w_k},$$
$$w_j \geq 0, \quad \sum_k w_k > 0.$$

生成器结合抽样方向和当前患者的事件关系选择问题，采样控制题型与推理要求，记录中的证据条件决定具体任务是否成立。

2.2 数据与环境双探索

为了在具体患者上选择问题，MedEvolve 首先从进化患者集合中探索可复用的提问模式。数据探索读取纵向轨迹，归纳记录中的事件角色、时间关系和证据条件，将结果表达为自然语言指导 K_D。例如，治疗前后变化分析将治疗调整作为事件锚点，将相关检查组织为可比较的证据；只有当前病例具备相应记录时，这一模式才能用于出题。因此，指导保留的是模式的适用条件，具体问题仍由目标患者的记录决定。

这些条件还需要落实到信息获取过程。环境探索通过工具交互识别可访问的记录类型，以及记录定位、关联检索和证据读取的方式，形成指导 K_E。生成器同时读取两类指导，将数据中的证据需求与环境中的获取能力结合。初始探索所得的 K_D 和 K_E 在后续轮次中固定复用，任务反馈则用于修订生成指导 g_r 与方向列表 W_r。

2.3 知识引导生成与证据核验

对患者 p，生成器接收预算内轨迹 X_p、固定指导 (K_D, K_E)、当前生成指导 g_r 和两个抽样方向 $Z_{p,r}$，通过一次模型调用输出候选批次：

$$\mathcal{T}_{p,r} = G(X_p, K_D, K_E, g_r, Z_{p,r}),$$
$$|\mathcal{T}_{p,r}| \leq 2.$$

生成器先在当前轨迹中选择满足指导条件的事件关系，再组织问题、候选参考答案与证据声明。对变化分析，证据需对应事件锚点和比较时段；对临床方案，答案需区分记录事实与推断，并容纳证据支持的等价方案。由此，原始记录支撑任务中的具体结论，探索指导约束关系选择和提问方式。

公共核验从环境读取引用的原始记录，先判断每项声明的来源支持，再判断这些声明是否共同支持问题和参考答案。逐来源核验检查具体事实，整题核验检查证据与提问目标的关系。通过核验的任务进入质量、推理深度与独立解题评价；未通过任务的缺陷原因进入生成反馈。

2.4 反馈驱动的策略自进化

生成任务的评价结果为下一轮出题提供修订依据。反馈模型按患者读取轨迹、任务、核验结果、质量与难度评价以及解题记录，归纳质量问题、推理要求、失败原因和修改建议，再将这些发现按类别汇总。按患者分析使反馈能够结合具体记录判断问题所在，汇总后的建议则作用于后续患者的生成策略。

其中，证据不足、事实错误和题意歧义需要转化为提问条件的修订，例如补充必要引用或缩小问题范围。对于核验通过但未完成的任务，反馈进一步结合工具轨迹和质量评价，分析是否涉及检索或推理困难。策略更新模型读取当前策略与这些反馈，通过一次调用输出新的生成指导和方向列表：

$$F_r = \mathrm{Merge}\big(\{\mathrm{Feedback}(X_p, \mathcal{T}_{p,r}, V_{p,r})\}_{p \in P_r}\big),$$
$$\theta_{r+1} = U_{\mathrm{LLM}}(\theta_r, F_r),$$

其中 $V_{p,r}$ 为该患者的评价和执行记录，P_r 为第 r 轮进化患者集合。通过 U_{LLM} 的修订，生

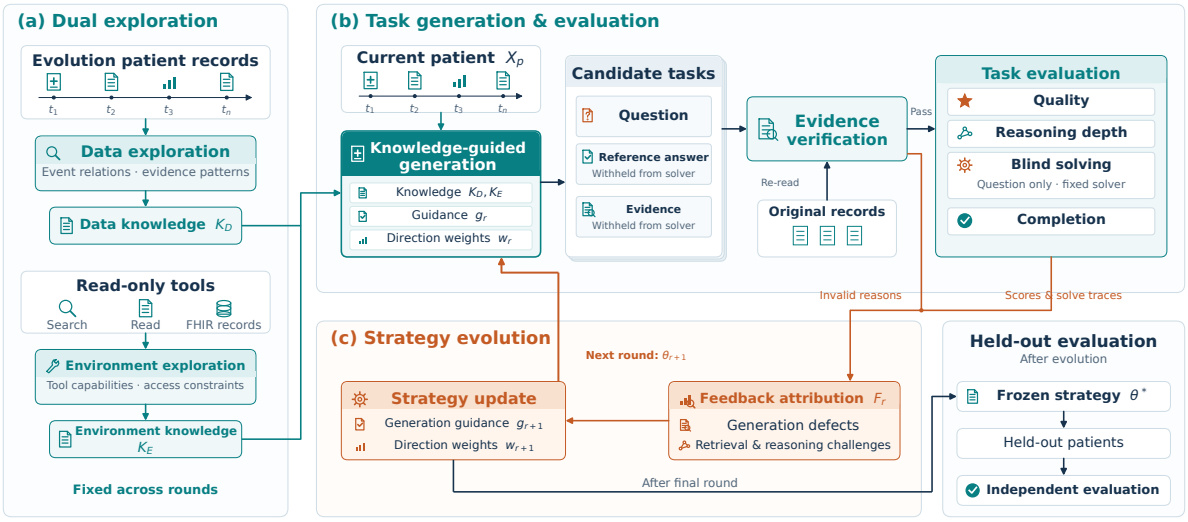


图 1. MedEvolve 方法概览。(a) 双探索分别从进化患者的纵向记录和只读工具交互中归纳数据指导 K_D 与环境指导 K_E，在后续轮次中固定复用。(b) 生成器结合当前患者 X_p、探索指导、生成指导 g_r 和方向权重 w_r 构建问题、参考答案与来源证据。核验阶段重新读取原始记录；通过核验的任务进入质量、推理深度、独立解题与完成评价，参考答案和证据声明不提供给解题 Agent。(c) 核验缺陷、评价结果与解题轨迹共同形成反馈 F_r，修订下一轮的生成指导与方向权重。进化结束后冻结策略，在独立患者上检验生成指导的迁移效果；该评测固定初始方向配比与抽样种子。

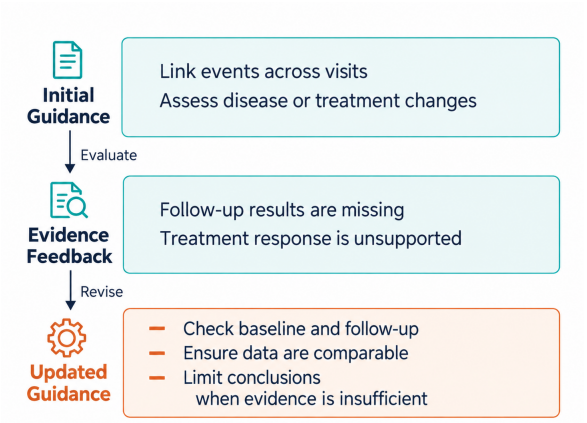


图 2. 一次策略自进化中的指导修订。核验反馈指出随访证据不足，更新后的指导增加基线、随访与数据可比性检查，并限定证据不足时的结论。图中文字根据一次进化记录概括。

成指导积累事件选择、证据组织和答案表述的经验，方向权重调整后续题型与推理要求的采样分布。策略自进化由此发生在出题侧，解题模型保持固定。

进化患者按轮次划分。每轮完成生成与评价后，更新策略用于下一轮患者；全部轮次结束后冻结策略，再到独立患者集合上生成并评价任务。这样，任务反馈能够参与策略形成，独立评测结果则用于检验冻结后的生成指导。

3 实验设置

3.1 研究问题与患者划分

实验回答三个问题：MedEvolve 能否改善有效产出、任务质量和推理要求；数据探索、环境探索及反馈更新分别起什么作用；不同来源的合成任务能否在固定模型权重下改善共同官方任务的完成表现。成本分析同时考察这些结果对应的实际调用投入。

研究覆盖 PhysicianBench 与 MedAgentBench。生成侧进化集和评测集按患者划分，同一患者不跨集合，独立评测结果不参与策略更新。两个生成模型和六种方法共享各环境的评测名单，环境之间分别报告结果。

名单以种子 42 和约四分之一的进化比例为基础，并受既有探索暴露范围约束，使历史探索患者保留在进化集。MedAgentBench 限定官方病历患者范围，额外仅有 Patient 资源的记录不进入实验。合成任务限定为基于既有轨迹的只读问答，采用完整时间范围的回顾性信息访问。抽样规则与信息访问边界见附录 B。

3.2 模型与对比方法

生成比较分别使用 GPT-5.4-nano 和 GPT-4o-mini；同一条件下，独立解题使用对应生成模型。质量与难度各由 GPT-5.4-nano 和 GPT-4o-mini 独立评价，取中位数并向下取整，保留原始评分和理由。核验与完成裁判使用 GPT-5.4-nano。不同评价协议的历史产物不能直接并入

表 1. 生成侧患者划分。

环境	患者总数	进化集	独立评测集	两轮进化患者数
PhysicianBench	108	27	81	13 / 14
MedAgentBench	100	25	75	12 / 13

同一主比较。

六种方法均接受公共核验与评价，每位患者最多输出两题。TaskCraft 使用原子任务、内部核验及深度和宽度扩展；Workflow 使用定位、生成和内部筛选；SingleShot 直接根据轨迹单次生成；SelfRefine 在当前患者批次内执行自反馈与修订（Madaan et al., 2023）；EnvExplore 用环境探索指导固定策略生成；MedEvolve 使用双探索和跨患者反馈更新。SingleShot 自主选择题型，Workflow 从题型候选池选择，其余方法按抽样方向构建任务；这些内部选择规则是方法差异的一部分。

输入轨迹按上下文预算选取，原始来源保留用于核验。相同题数上限不构成相同计算预算，方法内部探索、核验、修订和策略更新的实际调用分别统计。独立评测使用冻结策略的生成指导，并固定初始方向列表与抽样种子，以控制任务方向构成。医疗适配与内部预算见附录 C。

3.3 评价指标与统计

评价从请求的任务数量开始，依次记录实际生成量、核验覆盖和核验通过量。生成覆盖率以请求题数为分母，核验通过率以具有核验结果的题数为分母，生成不足、评价缺失和运行故障分别统计。由此可以区分方法能否产出任务，以及产出的任务是否具有证据支持。

对于核验通过的任务，质量评价从事实准确性、临床合理性、证据充分性和题目清晰度四个维度给出 1–5 分，并报告各维度均值和分布。推理深度分为事实查询、单步推理、整合推理和临床决策四级，第 3–4 级记为高阶推理。高阶占比附相应任务数量，去重引用数、资源类型数和引用记录时间跨度则用于描述这些任务的证据结构。

独立解题进一步评价任务在给定模型和预算下的完成表现，完成率分别以实际生成任务和具有完成评价的任务为分母。为了将这一表现与投入联系起来，生成成本统计探索、方法内部生成与检查、反馈及策略更新，公共核验、评分和解题成本另列。各阶段报告调用次数和输入、输出 token，并以核验通过题数归一化生成成本；未知用量保留缺失状态。

上述指标采用患者簇重采样估计区间，以保留同一患者多道任务之间的相关性。统计方案进行 1,000 次有放回重采样，种子为 42，使用 2.5% 与 97.5% 分位数构造 95% 区间；相同患者上的方法差异保持配对。评分覆盖、时间可解析覆盖和有效重采样次数随指标报告。正式统计结果尚未填入，评分尺度、分母和具体规则见附录 D。

4 结果与分析

4.1 生成任务的有效产出与质量

表 2–4 分别对应生成可靠性、四维质量和推理要求，按环境及生成模型拆分。当前正式结果均未填入，表中的“—”表示待填结果，不表示零或方法失败。

图 3 展示任务的核验状态与推理层级构成，图 4 展示核验通过任务的四维质量；表 2–4 补充相应数量、评分覆盖与证据结构。

质量均分描述已通过核验且评分成功的任务，不能代表全部请求任务。方法之间的比较需要联合考察通过题数、质量分布与高阶题数量：高阶占比可能来自少量任务，筛选后的高均分也可能伴随较低产量。完成率则描述给定解题模型和预算下的表现，只有结合任务可靠性才能解释其困难来源。

4.2 策略自进化

自进化实验比较初始策略与四轮反馈更新后的策略，共五个检查点。每轮结束后保存生成指导，在同一独立患者集上生成并评价任务；各检查点固定探索指导、生成与解题模型、初始方向列表、抽样种子、出题上限及公共评价。独立评测结果不参与反馈更新，因此检查点比较检验生成指导的变化，而非更新后方向配比的整体效果。

图 5 将四维质量、核验通过率和高阶有效题数并排展示。质量面板分别绘制事实准确性、临床合理性、证据充分性和题目清晰度的均值，不将四个维度合并成总分；核验通过率以具有核验结果的任务为分母，高阶有效题数统计通过核验且推理层级为 3–4 的任务。各指标附患者簇 95% 重采样区间，评分覆盖、核验覆盖和患者数随正式结果报告，相同患者上的检查点差异保持配对。

四轮更新使用进化集的不同患者批次，并保持每轮生成与评价预算一致。当前已有运行采用两轮划分（表 1），四轮实验需另行冻结患

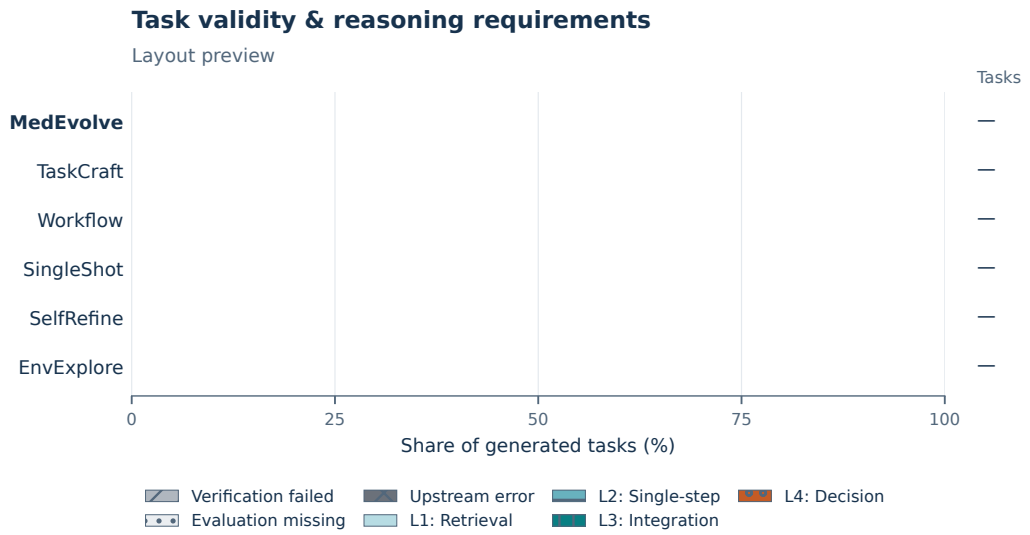


图 3. 生成任务的核验状态与推理层级分布。横轴为各类别占实际生成任务的比例，右侧报告生成题数；核验失败、评价缺失和上游故障与通过核验任务的四级推理要求分别展示。当前为待填数据的版式模板。

表 2. 实际生成量与公共核验结果。

方法	生成患者数	生成题数	核验题数	通过题数	核验通过率
MedEvolve	—	—	—	—	—
TaskCraft	—	—	—	—	—
Workflow	—	—	—	—	—
SingleShot	—	—	—	—	—
SelfRefine	—	—	—	—	—
EnvExplore	—	—	—	—	—

者分批与运行配置，并完成五个检查点的共同评测；逐轮训练批次上的成绩不替代固定患者集的策略比较。四轮正式结果尚未填入。

4.3 组件消融

为分析双探索与反馈更新的独立作用，表 5 比较完整 MedEvolve、去数据探索、去环境探索和关闭反馈更新四组。去数据探索保留环境指导与反馈更新，去环境探索保留数据指导与反馈更新；关闭反馈更新保留双探索及初始生成指导，在相同进化患者批次上生成与评价任务，但不修订策略。各组共享独立评测患者、模型、初始方向配比、抽样种子、出题上限和公共评价。

各组在四轮实验结束后比较核验通过题数、四维质量、高阶有效题数及实际生成 token。四维质量只统计核验通过且评分成功的任务，并附评分覆盖；成本包含探索、内部生成与检查、反馈及策略更新，公共评价成本另列。相同调用上限不代表实际 token 消耗相同，关闭更新组节省的反馈与修订调用纳入成本差异。EnvExplore 保留在主实验中作为组合对照，不用于单独归因某一组件。消融正式结果尚未填入。

4.4 下游经验学习

为了检验生成任务是否有助于经验学习，下游实验固定模型权重，将六种来源的合成任务分别接入 OpenClaw、Hermes Agent、ACE 和 Reflexion（Shinn et al., 2023）。每个环境包含 24 个来源与 Harness 组合；来源差异在同一 Harness 内比较，以各 Harness 的统一初始状态为参照。

为控制训练样本数量，每个来源仅纳入核验通过的只读任务，选取相同数量且不超过最小有效产量。以种子 42 按任务划分 70% 训练集和 30% 辅助测试集，训练数向下取整。PhysicianBench 冻结配置每来源 25 题，其中训练 17 题、辅助测试 8 题，使用 GPT-4o-mini，训练一轮。其他环境的实际数量和模型以其冻结清单为准。四种 Harness 共享同一来源的任务、划分和顺序。

训练时每题新建会话与医疗实例，参考答案和证据只在执行后供评审与学习使用，跨题保存技能、记忆或策略手册。训练结束后冻结

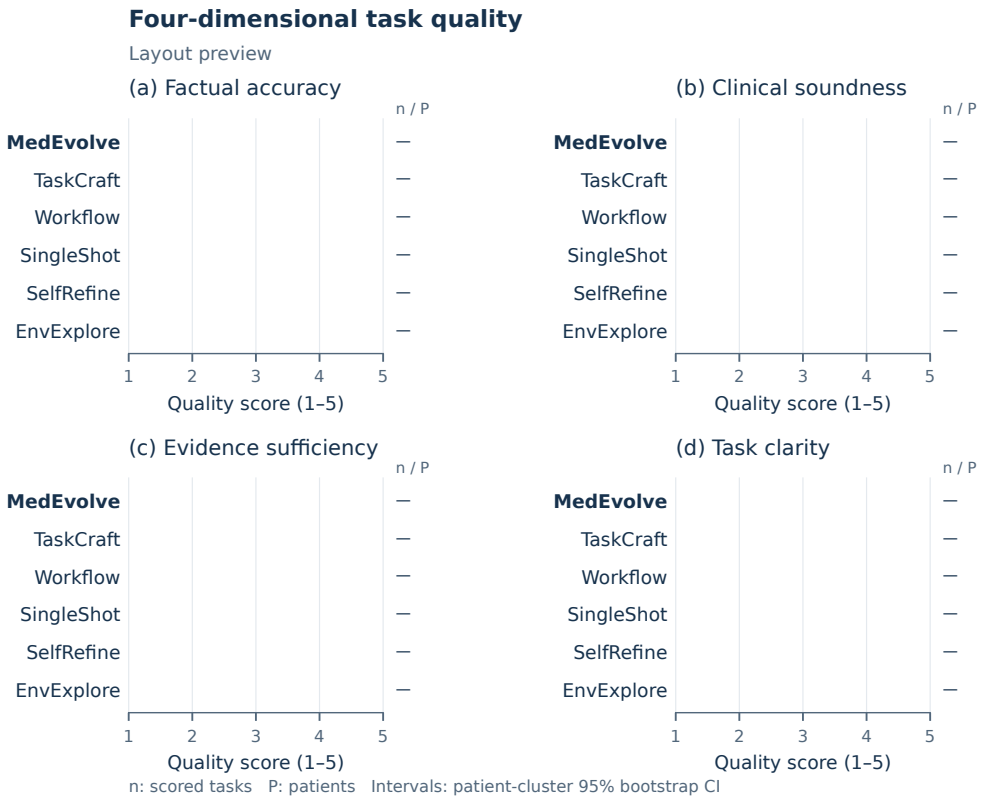


图 4. 核验通过任务的四维质量：事实准确性、临床合理性、证据充分性和题目清晰度。各维度采用 1–5 分尺度，正式结果报告均值及患者簇重采样的 95% 区间；n 与 P 分别表示评分题数和患者数。当前为待填数据的版式模板。

经验，不依据测试成绩选择版本。测试关闭经验写入和后台学习，每题从冻结快照开始，使用新会话和独立实例。具体学习机制与限制见附录 E。

各组完成训练后，主要评价采用同一环境的共同官方任务，并使用官方原生评分。对官方任务集 B 和经验状态 h，定义完整计划任务口径的成功率及百分点变化：

$$A(h) = \frac{N_{\text{confirmed success}}(h)}{|B|},$$
$$\Delta_m = 100\big(A(h_m) - A(h_0)\big).$$

其中 h_0 和 h_m 分别为初始与来源 m 训练后的经验。分子为获得有效评分且判定成功的任务数，分母为全部计划任务数；运行与评分故障单独列出，不能据该比率将故障归为临床失败。初始与最终均有有效评分的同题配对子集另报变化与区间，同时保留完整覆盖口径。

共同官方测试之外，各来源的辅助合成测试集检验其自身任务分布上的迁移。不同来源使用不同测试题，绝对成功率不用于跨来源排名。按任务划分可能共享患者，经验训练也可能与官方测试共享底层记录，因此分别记录患者重叠与题目近重复。当前下游正式成绩尚未填入，不能据推理层级或经验条目数量推断学习收益。

表 3. 核验通过任务的质量评分。各维度均值附患者级 95% 区间，评分题数表示评价覆盖。

方法	评分题数	事实准确性	临床合理性	证据充分性	题目清晰度
MedEvolve	—	—	—	—	—
TaskCraft	—	—	—	—	—
Workflow	—	—	—	—	—
SingleShot	—	—	—	—	—
SelfRefine	—	—	—	—	—
EnvExplore	—	—	—	—	—

表 4. 推理要求与证据结构。证据跨度仅针对时间可解析任务，覆盖数随结果报告。

方法	高阶题数 / 评分题数	高阶占比	平均证据数	平均资源类型数	跨度中位数（天）
MedEvolve	—	—	—	—	—
TaskCraft	—	—	—	—	—
Workflow	—	—	—	—	—
SingleShot	—	—	—	—	—
SelfRefine	—	—	—	—	—
EnvExplore	—	—	—	—	—

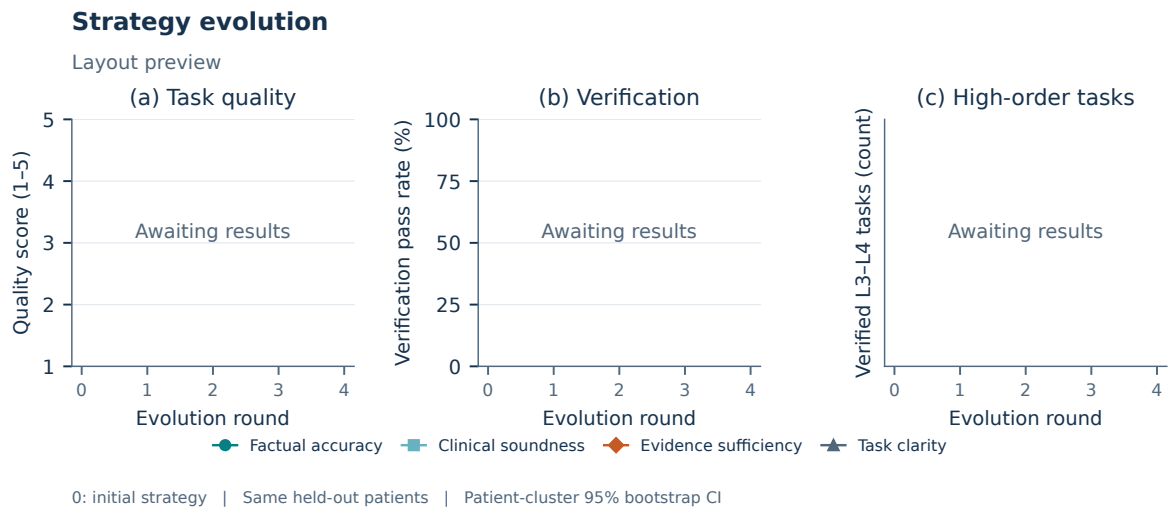


图 5. 固定独立患者集上的策略自进化。横轴为进化次数，0 表示初始策略，1–4 表示各轮更新后的策略。(a) 核验通过任务的四维质量均值；(b) 公共核验通过率；(c) 核验通过且推理层级为 3–4 的任务数。正式结果以点和折线表示估计量，误差线为患者簇 95% 重采样区间；缺失检查点不连线。当前为待填数据的版式模板。

表 5. 四组组件消融结果。四维质量依次为事实准确性、临床合理性、证据充分性和题目清晰度，采用 1–5 分尺度；正式结果附患者级区间及评价覆盖。各环境与生成模型分别报告。

配置	核验通过题数	四维质量	高阶有效题数	生成 token
完整 MedEvolve	—	—/—/—/—	—	—
去数据探索	—	—/—/—/—	—	—
去环境探索	—	—/—/—/—	—	—
关闭反馈更新	—	—/—/—/—	—	—

表 6. 共同官方任务上的下游效果。每个环境分别成表，单元格为最终成功率及相对自身初始状态的百分点变化，区间和评分覆盖另附。

任务来源 / 状态	OpenClaw	Hermes Agent	ACE	Reflexion
初始状态	—	—	—	—
MedEvolve	—	—	—	—
TaskCraft	—	—	—	—
Workflow	—	—	—	—
SingleShot	—	—	—	—
SelfRefine	—	—	—	—
EnvExplore	—	—	—	—

5 讨论与结论

5.1 讨论

不同病例提供的出题机会各异，使生成指导需要同时具有可复用性和适用条件。MedEvolve 以自然语言表达临床模式及其证据需求，使同一模式可以在满足条件的患者上形成具体问题，也允许生成器在其他患者上选择不同方向。随着进化患者提供更多任务反馈，生成策略进一步吸收对事件选择、证据组织和答案表述的修订。指导能否被遵循、能否在新患者上发挥作用，由任务评价和控制实验检验。

这种生成侧的变化还需要与下游学习效果联系起来。质量与证据结构评价反映任务的构建水平，共同官方任务则检查由这些任务积累的经验是否有助于解题。两类结果共同决定任务来源的价值；较高的推理层级本身不足以说明学习收益，单个下游成功案例也不能代表整体效果。

5.2 结论

本文提出 MedEvolve，通过数据与环境双探索识别适合不同病例的提问模式，并利用任务评价反馈推动生成策略自进化。生成器结合模式的证据条件和当前患者记录构建任务，策略则在跨患者反馈中修订出题指导与方向权重。研究以生成比较、组件控制和共同官方任务分别考察任务构建、策略自进化及下游价值，正式实验结果尚未填入。

局限性（Limitations）

病例记录的完整性、时间信息和模型输入预算限制了可发现的提问模式，轨迹裁剪也可能遗漏关键依据。同一环境内的患者独立划分只能检验该环境中的迁移，跨机构或跨数据来源的泛化仍需另外评价。当前生成采用回顾性信息访问，不启用时间视角隔离，因此不代表临床当时可获得的信息范围。

这些数据限制也影响自动评价。两个模型的评分聚合不能消除共同偏差，现有记录未必足以判定所有临床方案；质量评分又仅覆盖核验通过且评分成功的任务，复杂任务可能因单条引用失败而被整体拒绝。因此，评分均值需要结合评价覆盖和有效产量解释。

对策略自进化的解释同样受比较条件约束。独立评测固定方向配比，主要检验生成指导更新，未覆盖更新后方向分布的整体效果。反馈模型给出的归因和建议也可能有误，策略更新不保证后续结果单调改善。

下游实验中，合成训练与辅助测试按任务划分，可能共享患者，官方测试也可能与经验训练共享底层记录。当前单种子、单次训练配置不能衡量跨运行稳定性，患者簇重采样仅反映测试样本不确定性。不同 Harness 的原生学习触发和调用限制存在差异，任务来源的比较因而限定在同一 Harness 内。

参考文献

Jiang, Yixing, et al. 2025. MedAgentBench: A Realistic Virtual EHR Environment to Benchmark Medical LLM Agents. arXiv:2501.14654.

Liu, Ruoqi, et al. 2026. PhysicianBench: Evaluating LLM Agents in Real-World EHR Environments. arXiv:2605.02240.

Shi, Dingfeng, et al. 2025. TaskCraft: Automated Generation of Agentic Tasks. arXiv:2506.10055.

Mai, Shinji, et al. 2025. CuES: A Curiosity-driven and Environment-grounded Synthesis Framework for Agentic RL. arXiv:2512.01311.

Shinn, Noah, et al. 2023. Reflexion: Language Agents with Verbal Reinforcement Learning. arXiv:2303.11366.

Zhai, Yunpeng, et al. 2025. AgentEvolver: Towards Efficient Self-Evolving Agent System. arXiv:2511.10395.

Madaan, Aman, et al. 2023. Self-Refine: Iterative Refinement with Self-Feedback. arXiv:2303.17651.

Kassis, Timothy, Vinayak Agarwal, Yuhuan He, Darshil Patel, and Aubrey M. Brueckner.

2026. Scientific Agent Skills: A Library of Procedural Knowledge for Research Agents. https://doi.org/10.48550/arXiv.2609.00065.

A 探索与生成接口

A.1 数据探索

探索工具提供开放患者名单、预算内轨迹及可选压缩摘要。输入材料保留患者标识、原始来源和覆盖标记，输出为不绑定患者的自然语言指导。指导归纳数据组织、时间变化、事件关系、证据引用与可支持的问题，不保留个体临床值或来源编号。

压缩摘要用于定位模式，原始记录用于支持具体事实。记录缺失与材料裁剪分别解释。指导中的时间窗口、记录数量或临床关系属于模型归纳的提问约束，不构成对所有患者统一适用的硬编码医学规则。

A.2 环境探索

环境探索在独立实例中访问开放患者的原生只读工具。指导记录已验证参数、返回结构、分页与裁剪行为、典型检索方式，并区分调用失败和未验证能力。环境内的具体患者观察不进入通用指导。

A.3 任务生成与策略

任务包含患者标识、临床题型、问题、候选参考答案、来源标识与逐来源事实声明，以及执行要求；当前公共生成接口要求时间视角字段为空，执行要求为只读。生成调用输入预算内轨迹、两类探索指导、当前生成指导和两个采样方向，输出最多两题。

生成策略由自然语言指导和方向列表组成；方向包含五类临床题型之一、难度描述与非负权重。方向按权重采样，允许同一题型对应不同临床模式；至少一个权重为正。数据与环境指导在策略更新期间固定，更新只修订生成指导和方向列表。进化阶段按当前方向权重抽样；独立评测固定初始方向列表与抽样种子，读取当前策略的生成指导。

B 环境、患者与信息访问

PhysicianBench 的生成患者池为 108 人，MedAgentBench 为官方范围内的 100 人。按种子 42 和既有探索暴露约束冻结进化与评测名单。进化患者分为互不重叠的两轮：PhysicianBench 为 13 与 14 人，MedAgentBench 为 12 与 13 人；评测患者分别为 81 与 75 人。

原始轨迹按记录时间组织，模型输入按预算选取；证据核验读取原始来源，不以输入摘要替代来源。初始探索和任务生成只开放查询工具。解题工具依环境与任务执行要求提供，经验训练的合成任务进一步限定为只读。当前公共生成接口未启用时间视角属性，问题中的时间限定不等同于服务端隐藏后续记录。

经验学习另按合成任务划分训练与辅助测试，不能与生成侧患者划分混用。冻结清单记录选中题目、患者、训练与测试划分、文件摘要及生成来源。官方任务评测另记录任务版本、患者范围及与经验训练的重叠。

C 生成方法与预算

TaskCraft 将患者记录与只读 FHIR 工具映射到原方法的结论抽取、原子任务生成、核验与扩展流程。深度和宽度分支均从原子任务出发，彼此没有先后依赖；两条分支共享生成总预算。原子、深度和宽度候选的实际产量及接纳情况分别记录，以区分扩展机制和最终筛选的影响。医疗适配与原论文完整实验复现分别解释。

Workflow 固定执行定位、生成和内部检查，检查只筛选候选。SingleShot 根据轨迹单次生成最多两题。SelfRefine 在同一患者批次内执行初稿、自反馈和修订，最多三次自评、两次修订，全部通过时提前结束。EnvExplore 先获取环境指导，再用固定初始策略生成任务。各方法共享输出结构和公共评价，内部调用与筛选记录分别保存。

主方法初始探索完成后执行两轮生成侧策略进化，每轮按患者归纳反馈并汇总更新。批次输出的结构或配额校验失败保留为生成失败。反馈和更新调用失败不视为进化成功。输入裁剪、实际调用与预算耗尽分别记录。

模型路由、上下文上限、输出限制和工具预算以冻结运行配置为准。同一比较中报告各方法预算与实际用量；相同出题数量不表述为严格相同 token 预算。探索和更新计入主方法总成本，公共评价成本单列，历史复用调用按原始记录去重计数。

D 评分、汇总与统计

D.1 质量与推理深度

推理深度依据问题要求及证据结构标注：第 1 级直接读取事实，第 2 级结合记录与临床知识完成单步判断，第 3 级跨记录比较或整合信息，第 4 级综合证据权衡风险收益并提出方案。临床题型与推理层级分别记录，不把治疗规划题自动判为最高层级。

对任务 i、质量维度 d，两个模型的原始评分为 $s_{i,d}^{(1)}$ 与 $s_{i,d}^{(2)}$，最终评分为

$$s_{i,d} = \left\lfloor \text{median}\left(s_{i,d}^{(1)}, s_{i,d}^{(2)}\right) \right\rfloor .$$

表 7. 四维质量评分标准。各维度独立评分。

分数	事实准确性	临床合理性	证据充分性	题目清晰度
5	数值、单位、药物、剂量与时间准确	推理严密，方案与风险考虑充分	关键事实和结论均有明确支持	目标、背景与操作要求明确
4	核心准确，存在次要细节瑕疵	基本合理，个别步骤有不足	主要结论有支持，细节引用不完整	基本清晰，个别细节需推断
3	多数准确，少量非关键错误	方向正确，但遗漏重要考虑	核心结论有支持，部分推理缺引用	方向明确，但缺关键背景
2	关键事实错误	有明显漏洞或违背常规实践	关键结论缺支持	目标模糊、矛盾或缺必要限定
1	多处严重错误或编造数据	推理错误或方案有明显风险	主要依赖未支持的推断或编造	无法理解或执行

表 8. 生成任务的比率分母。

指标	分子	分母
生成覆盖率	实际生成题数	请求题数
核验覆盖率	具有核验结果的题数	实际生成题数
核验通过率	核验通过题数	具有核验结果的题数
高阶题占比	深度为 3–4 的题数	具有难度评分的题数
维度高质量占比	该维度评分不低于 4 的题数	具有该维度评分的题数
全部生成任务完成率	判定完成题数	实际生成题数
已评价任务完成率	判定完成题数	具有完成评价的题数

表 9. 四种 Harness 的经验载体与更新机制。

Harness	持久化经验	训练更新	测试状态
OpenClaw	技能与独立状态目录	原生 Skill Workshop，记录是否触发	读取冻结技能，关闭学习与后台维护
Hermes Agent	技能与记忆	原生技能和记忆机制	保留读取，关闭写入与整理
ACE	策略手册	Reflector 和 Curator 更新	只运行 Generator
Reflexion	反思与可迁移经验	失败反思及限定次数重试	只运行 Actor，读取经验

难度采用同样聚合规则，保留两个原始层级与理由。正式协议要求两份有效输出，不以单个成功裁判替代缺失评价。质量评分材料包含题目、参考答案、证据、轨迹与核验结果；难度评分依据任务要求和自动复杂度。原始评分用于分歧分析。

D.2 证据结构与比率

对引用来源去重得到 S_i，证据数量为 $|S_i|$，资源类型数由可识别类型前缀去重得到。引用记录中可解析的时间集合为 T_i，其跨度为

$$\Delta_i = \frac{\max T_i - \min T_i}{1\ \text{天}}.$$

无可解析时间时记缺失，只有一个可解析时间时为零。报告时间可解析任务数，跨度分布和中位数仅使用非缺失值。

分母为零时记缺失。质量均值、层级分布和证据结构分别报告覆盖数。临床失败、证据不足、题意歧义、工具故障、环境故障与模型故障分别汇总，不由运行状态推断任务完成。

D.3 不确定性估计

统计方案以患者为簇，进行 1,000 次有放回重采样，种子为 42，取分布的 2.5% 与 97.5% 分位数作为 95% 区间。患者的全部题目共同进入样本，相同患者上的方法差异保留配对。重采样分母为零的指标记缺失，不转换为零；区间随指标有效重采样次数报告。

官方任务的初始与最终状态先按任务标识配对，再按患者簇重采样；共同任务和共同有效评分分别报告。单次训练结果不附跨训练标准差。

E 经验学习与官方评测

各组独立保存配置和经验，从统一初始状态开始。Reflexion 的跨任务经验提炼为医疗适配：保存适用条件、操作步骤和错误教训，不保存患者标识、个体临床值或逐题答案；新题按冻结规则读取最多三条相关经验。测试不根据评分进行反思或重试。

PhysicianBench 当前配置每来源 25 题，训练 17 题、辅助测试 8 题，训练一轮、种子 42。执行与经验更新使用 GPT-4o-mini，单题执行轮次上限 30、工具调用上限 200、执行超时 900 秒，学习轮次上限 10、超时 300 秒。各 Harness

采用原生可用限制，后台调用或原生组件内部用量无法完整计数时标为未知，不表述为统一硬预算拦截。

官方评测锁定任务与评分资产版本。PhysicianBench 使用官方任务和检查点评分，提供实际文件交付、执行轨迹和本题 FHIR 实例；任务成功率与平均检查点得分分别报告。MedAgentBench 按冻结配置选择任务版本并使用官方完成评判，版本间结果分别报告。官方资产缺失或评分故障保留为不可用结果，不以公共模型裁判替代原生分数。

测试评分与解题隔离，评分完成前保留实际使用的医疗实例。每题使用冻结经验副本，不将参考答案、评分结果或完整会话回写到最终经验。测试前后核对冻结经验摘要，报告计划任务数、评分覆盖、初始与最终成绩以及完整与配对口径的提升。

F 补充结果与案例

补充结果和经过作者核对的案例尚未填入。

补充结果按环境、生成模型和方法报告质量分布、临床题型、推理层级、证据跨度及故障构成。TaskCraft 另报告原子与扩展候选的产量和最终接纳比例。合成辅助测试按来源报告初始与最终成绩、患者重叠和配对样本量。

案例保留问题、候选参考答案、原始证据、核验与质量结果，以及相关解题轨迹。临床事实、模型推断与可迁移经验分别展示，时间轴仅使用实际记录。正式表格中的空值表示结果未填入，缺失评价与不适用指标在正式结果中分别标识。

G 写作辅助工具

中文稿的结构组织、方法描述核对与证据状态检查使用 Scientific Agent Skills 的 scientific-writing 技能（Kassis et al., 2026）辅助。文献与科学结论的最终核验由作者负责。